

Estadística_vs_Machine_Learning

July 30, 2026

1 ¿Cuándo la estadística deja de ser suficiente y comienza el Machine Learning?

1.1 Un enfoque metodológico mediante la simulación de un sistema agrícola

Autor: Víctor Hugo Villegas Ríos

Consultor Freelance en Ciencia de Datos Aplicada, Inteligencia Ambiental y Analítica Territorial

1.2 Presentación del proyecto

La elección entre métodos estadísticos tradicionales y algoritmos de Machine Learning constituye una de las decisiones más importantes dentro del proceso de análisis de datos. Sin embargo, esta decisión suele abordarse desde la comparación de algoritmos o métricas predictivas, dejando en segundo plano la comprensión del fenómeno que se desea modelar.

Este notebook propone un enfoque diferente.

A través del diseño de un Motor de Simulación Agronómica, se construyen cuatro experimentos con niveles crecientes de complejidad, permitiendo analizar cómo evoluciona el desempeño de distintos modelos predictivos conforme aumentan las relaciones no lineales y las interacciones entre variables.

Más que comparar algoritmos, este trabajo busca demostrar que la selección de un modelo debe ser una consecuencia de la complejidad del fenómeno y no únicamente de la disponibilidad de herramientas computacionales.

Durante el desarrollo se integran conceptos de Agronomía, Estadística, Ciencia de Datos y Machine Learning, siguiendo un proceso metodológico que comprende:

- Diseño conceptual del sistema agrícola.
- Construcción de un conjunto de datos mediante simulación.
- Análisis Exploratorio de Datos (EDA).
- Entrenamiento de modelos predictivos.
- Comparación del desempeño mediante métricas objetivas.
- Interpretación de variables relevantes.
- Extracción de lecciones metodológicas.

El resultado es un caso práctico que evidencia cómo el conocimiento del dominio constituye el punto de partida para desarrollar modelos predictivos robustos, interpretables y técnicamente consistentes.

Porque antes de elegir un algoritmo, debemos comprender el fenómeno.

1.3 Objetivos del notebook

1.3.1 Objetivo general

Analizar la transición entre la Estadística Tradicional y el Machine Learning mediante un sistema agrícola simulado, identificando el momento en que la complejidad del fenómeno requiere modelos predictivos capaces de representar relaciones no lineales e interacciones entre variables.

1.3.2 Objetivos específicos

- Diseñar un Motor de Simulación Agronómica basado en conocimiento experto.
- Construir un conjunto de datos con complejidad creciente.
- Aplicar técnicas de Análisis Exploratorio de Datos (EDA).
- Entrenar modelos de Regresión Lineal, Random Forest y XGBoost.
- Comparar el desempeño predictivo mediante métricas objetivas.
- Analizar la interpretabilidad de los modelos.
- Extraer lecciones metodológicas para la selección de modelos predictivos.

2 Nota metodológica

Los datos utilizados en este notebook fueron generados de forma sintética mediante Python.

Esta decisión fue tomada deliberadamente para construir un experimento completamente controlado que permita comparar distintos enfoques analíticos bajo diferentes niveles de complejidad.

Los resultados obtenidos **no representan un cultivo específico**.

Su propósito es ilustrar principios generales que posteriormente pueden aplicarse a datos reales provenientes de la agricultura, el medio ambiente o los recursos naturales.

La transparencia metodológica constituye un principio fundamental de este trabajo.

3 Objetivos

Este notebook busca responder tres preguntas fundamentales.

3.1 Objetivo general

Analizar cómo cambia el desempeño de la estadística tradicional y del Machine Learning a medida que aumenta la complejidad de un problema agrícola.

3.2 Objetivos específicos

- Construir un conjunto de datos sintéticos completamente reproducible.
- Analizar los datos utilizando herramientas estadísticas.
- Comparar modelos de Regresión Lineal, Random Forest y XGBoost.

- Visualizar cómo cambia la capacidad predictiva cuando aparecen relaciones no lineales e interacciones entre variables.
- Comprender en qué situaciones cada metodología resulta más apropiada.

4 ¿Cómo desarrollaremos este experimento?

El experimento se construirá de manera progresiva.

Comenzaremos con un problema extremadamente sencillo donde el rendimiento depende prácticamente de una sola variable.

Posteriormente iremos aumentando la complejidad incorporando nuevas variables e interacciones.

Cada etapa representará un nivel diferente de dificultad.

De esta manera podremos observar objetivamente cuándo la estadística tradicional continúa siendo suficiente y cuándo el Machine Learning comienza a aportar una ventaja predictiva.

El objetivo no es encontrar “el mejor algoritmo”.

El objetivo es comprender cómo evoluciona el problema.

5 Los cuatro escenarios del experimento

Durante este trabajo construiremos cuatro conjuntos de datos.

5.1 Escenario 1

Relación prácticamente lineal.

Una variable explica la mayor parte del rendimiento.

5.2 Escenario 2

Aparece una segunda variable importante.

Las relaciones siguen siendo relativamente simples.

5.3 Escenario 3

Las variables comienzan a interactuar entre sí.

La realidad se vuelve considerablemente más compleja.

5.4 Escenario 4

Relaciones no lineales, múltiples interacciones y ruido.

Aquí evaluaremos el verdadero potencial del Machine Learning.

6 Antes de comenzar...

Existe una idea que acompañará todo este notebook.

La estadística nos ayuda a comprender los datos.

El Machine Learning aprende de esos datos para realizar predicciones.

No son herramientas que compiten.

Son herramientas que se complementan.

La elección dependerá siempre de la naturaleza del problema que deseamos resolver.

```
[1]: import numpy as np
import pandas as pd
...
```

[1]: Ellipsis

7 Capítulo 1

8 ¿Qué ocurre cuando una sola variable explica casi todo el fenómeno?

Antes de estudiar problemas complejos, comenzaremos con un escenario extremadamente sencillo.

Imaginemos un cultivo ficticio cuyo rendimiento depende principalmente de una sola variable: **la precipitación**.

Aunque sabemos que esta situación rara vez ocurre en la realidad, resulta ideal para comprender cómo responde la estadística tradicional cuando las relaciones entre las variables son prácticamente lineales.

Este primer experimento servirá como punto de partida.

A medida que avancemos en el notebook, iremos incorporando nuevas variables e interacciones hasta construir escenarios mucho más cercanos a la complejidad que encontramos en los sistemas agrícolas reales.

La pregunta que intentaremos responder es muy simple:

Si una sola variable explica casi todo el fenómeno, ¿es realmente necesario utilizar Machine Learning?

La respuesta la obtendremos a partir de los datos.

8.1 Experimento 1

Para este primer escenario construiremos un conjunto de datos sintéticos donde el rendimiento del cultivo dependerá casi exclusivamente de la cantidad de lluvia recibida.

Supondremos que:

- existe una relación prácticamente lineal entre ambas variables;

- el resto de los factores permanecen constantes;
- únicamente incorporaremos un pequeño nivel de variabilidad aleatoria para representar las diferencias naturales que siempre existen en cualquier sistema biológico.

Este será el escenario más sencillo de todo el proyecto.

Precisamente por ello, esperamos que un modelo de Regresión Lineal describa adecuadamente el comportamiento del cultivo.

8.2 ¿Qué esperamos encontrar?

Antes de ejecutar cualquier modelo, vale la pena formular una hipótesis.

Si el rendimiento depende casi exclusivamente de la lluvia, es razonable esperar que:

- exista una correlación positiva elevada entre ambas variables;
- una Regresión Lineal represente adecuadamente el comportamiento del cultivo;
- los modelos de Machine Learning no ofrezcan una mejora significativa respecto a la estadística tradicional.

En otras palabras, este primer experimento nos permitirá comprobar que, cuando la realidad es sencilla, la estadística continúa siendo una herramienta extraordinariamente eficaz.

```
[2]: # =====
# EXPERIMENTO 1
# ¿Qué ocurre cuando una sola variable explica casi todo
# el rendimiento del cultivo?
# =====

# En este escenario construiremos un conjunto de datos
# sintéticos donde la precipitación será la principal
# variable explicativa del rendimiento.
#
# El objetivo NO es representar un cultivo real.
#
# El objetivo es construir un problema sencillo que permita
# observar el comportamiento de la estadística tradicional.
```

```
[3]: # =====
# Generación del Dataset Sintético - Experimento 1
# =====
#
# En este primer experimento simularemos 1.000 campañas
# agrícolas independientes.
#
# El supuesto principal es muy sencillo:
#
# El rendimiento del cultivo depende casi exclusivamente
# de la cantidad de precipitación recibida durante la campaña.
#
```

```

# Para representar la variabilidad natural que existe en
# cualquier sistema biológico, incorporaremos un pequeño
# componente aleatorio (ruido).
#
# Este conjunto de datos NO representa un cultivo específico.
# Su objetivo es únicamente ilustrar un escenario donde una
# relación lineal describe adecuadamente el fenómeno.
# =====

import numpy as np
import pandas as pd

# -----
# Garantizar reproducibilidad del experimento
# -----

np.random.seed(42)

# -----
# Número de campañas agrícolas simuladas
# -----

n = 1000

# -----
# Variable independiente:
# Precipitación acumulada durante la campaña (mm)
# -----

precipitacion = np.random.uniform(
    low=300,
    high=1200,
    size=n
)

# -----
# Variabilidad natural del sistema
# -----

ruido = np.random.normal(
    loc=0,
    scale=0.8,
    size=n
)

# -----
# Modelo conceptual

```

```

# -----

rendimiento = (
    2
    + 0.008 * precipitacion
    + ruido
)

# -----
# Construcción del Dataset
# -----

df_exp1 = pd.DataFrame({
    "Precipitacion_mm": precipitacion,
    "Rendimiento_t_ha": rendimiento
})

# -----
# Resumen del experimento
# -----

print("=" * 60)
print("EXPERIMENTO 1 - DATASET SINTÉTICO")
print("=" * 60)

print(f"Campañas agrícolas simuladas : {len(df_exp1):,}")
print(f"Variables                      : {df_exp1.shape[1]:,}")

print("\nPrimeras observaciones:\n")

display(df_exp1.head())

```

```
=====
EXPERIMENTO 1 - DATASET SINTÉTICO
=====
```

```
Campañas agrícolas simuladas : 1,000
Variables                      : 2
```

```
Primeras observaciones:
```

	Precipitacion_mm	Rendimiento_t_ha
0	637.086107	7.238850
1	1155.642876	10.176868
2	958.794548	9.974515
3	838.792636	9.198810
4	440.416776	5.971167

8.3 ¿Qué acabamos de construir?

En este primer experimento hemos generado **1.000 campañas agrícolas simuladas**, donde cada observación representa una combinación de precipitación y rendimiento del cultivo.

A simple vista podemos notar dos aspectos importantes:

- La **precipitación** presenta valores diferentes en cada campaña, simulando la variabilidad climática que puede existir entre distintas temporadas agrícolas.
- El **rendimiento** también varía entre campañas, aunque sigue una tendencia relacionada con la cantidad de lluvia recibida.

En este escenario todavía no intervienen otros factores como la temperatura, el tipo de suelo o la fertilización. Hemos construido deliberadamente un sistema muy sencillo donde la precipitación explica casi todo el comportamiento del cultivo.

Este será nuestro punto de partida.

En los siguientes experimentos iremos incorporando nuevas variables e interacciones para observar cómo aumenta la complejidad del problema y cómo cambia el desempeño de los distintos modelos de predicción.

8.4 Primer vistazo a nuestros datos

Antes de construir cualquier modelo predictivo, es importante conocer el conjunto de datos con el que vamos a trabajar.

En un proyecto real, este paso permite identificar aspectos como:

- el número de observaciones disponibles;
- el tipo de variables;
- posibles valores faltantes;
- la distribución general de los datos.

En nuestro experimento sabemos que los datos fueron generados de forma controlada y, por lo tanto, no esperamos encontrar inconsistencias.

Sin embargo, realizaremos este análisis porque forma parte del proceso que seguiría cualquier proyecto de Ciencia de Datos.

Comprender los datos siempre es el primer paso antes de intentar predecirlos.

```
[4]: # =====  
# Exploración inicial del conjunto de datos  
# =====  
  
print("=" * 60)  
print("INFORMACIÓN GENERAL DEL DATASET")  
print("=" * 60)  
  
display(df_exp1.info())  
  
print("\n")
```

```
print("=" * 60)
print("ESTADÍSTICAS DESCRIPTIVAS")
print("=" * 60)

display(df_exp1.describe().round(2))
```

```
=====
INFORMACIÓN GENERAL DEL DATASET
=====
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1000 entries, 0 to 999
Data columns (total 2 columns):
#   Column                Non-Null Count  Dtype
---  -
0   Precipitacion_mm      1000 non-null   float64
1   Rendimiento_t_ha      1000 non-null   float64
dtypes: float64(2)
memory usage: 15.8 KB

None
```

```
=====
ESTADÍSTICAS DESCRIPTIVAS
=====
```

	Precipitacion_mm	Rendimiento_t_ha
count	1000.00	1000.00
mean	741.23	8.01
std	262.92	2.21
min	304.17	2.81
25%	512.38	6.16
50%	747.13	8.04
75%	969.89	9.82
max	1199.75	13.28

8.5 ¿Qué nos dicen estas estadísticas?

Las estadísticas descriptivas muestran un comportamiento coherente con el experimento que hemos diseñado.

Observamos que la precipitación presenta una amplia variabilidad entre campañas agrícolas, mientras que el rendimiento cambia siguiendo una tendencia similar.

En este escenario no existen valores faltantes ni observaciones atípicas, ya que los datos fueron generados de forma controlada.

Hasta este momento, todo indica que estamos trabajando con un problema relativamente sencillo, donde una única variable parece explicar gran parte del comportamiento del cultivo.

El siguiente paso consistirá en visualizar esa relación para comprobar si realmente existe una tendencia lineal entre la precipitación y el rendimiento.

```
[5]: # =====
# Figura 1
# Cuando una variable parece explicarlo todo
# =====

from sklearn.linear_model import LinearRegression
import matplotlib.pyplot as plt

# -----
# Preparación de los datos
# -----

X = df_exp1[["Precipitacion_mm"]]
y = df_exp1["Rendimiento_t_ha"]

# -----
# Ajuste del modelo de Regresión Lineal
# -----

modelo_lr = LinearRegression()
modelo_lr.fit(X, y)

# Predicciones de la línea de regresión
pred_lr = modelo_lr.predict(X)

# -----
# Ordenar los datos para dibujar correctamente la línea
# -----

orden = X["Precipitacion_mm"].argsort()

X_ordenado = X.iloc[orden]
pred_ordenada = pred_lr[orden]

# -----
# Construcción del gráfico
# -----

plt.figure(figsize=(10, 6))

# Nube de puntos
plt.scatter(
    df_exp1["Precipitacion_mm"],
    df_exp1["Rendimiento_t_ha"],
```

```

        alpha=0.65,
        s=40,
        color="#2E86C1",
        edgecolor="white",
        linewidth=0.4,
        label="Campañas agrícolas simuladas"
    )

    # Línea de regresión
    plt.plot(
        X_ordenado,
        pred_ordenada,
        color="#2E8B57",
        linewidth=3,
        label="Regresión Lineal"
    )

    # -----
    # Personalización
    # -----

    plt.title(
        "Figura 1. Cuando una variable parece explicarlo todo",
        fontsize=16,
        weight="bold",
        pad=15
    )

    plt.xlabel(
        "Precipitación acumulada durante la campaña (mm)",
        fontsize=12
    )

    plt.ylabel(
        "Rendimiento del cultivo (t/ha)",
        fontsize=12
    )

    plt.grid(True, alpha=0.25)

    plt.legend(frameon=True)

    plt.figtext(
        0.5,
        -0.03,
        "Datos sintéticos generados en Python • Elaboración propia",
        ha="center",
    )

```

```


        fontsize=10,
        color="gray"
    )

plt.tight_layout()

plt.show()

```

Figura 1. Cuando una variable parece explicarlo todo



Datos sintéticos generados en Python • Elaboración propia

```

[6]: # =====
# Evaluación del modelo de Regresión Lineal
# =====

from sklearn.metrics import (
    r2_score,
    mean_squared_error,
    mean_absolute_error
)

import numpy as np

# -----
# Correlación de Pearson
# -----

```

```

corr_pearson = df_exp1["Precipitacion_mm"].corr(
    df_exp1["Rendimiento_t_ha"]
)

# -----
# Métricas del modelo
# -----

r2_lr = r2_score(y, pred_lr)

rmse_lr = np.sqrt(
    mean_squared_error(y, pred_lr)
)

mae_lr = mean_absolute_error(y, pred_lr)

# -----
# Resultados
# -----

print("=" * 60)
print("DESEMPEÑO DEL MODELO - REGRESIÓN LINEAL")
print("=" * 60)

print(f"Correlación de Pearson : {corr_pearson:.4f}")

print(f"R2 : {r2_lr:.4f}")

print(f"RMSE : {rmse_lr:.4f}")

print(f"MAE : {mae_lr:.4f}")

```

```

=====
DESEMPEÑO DEL MODELO - REGRESIÓN LINEAL
=====
Correlación de Pearson : 0.9341
R2 : 0.8725
RMSE : 0.7899
MAE : 0.6298

```

8.6 ¿Qué nos indican estas métricas?

Los resultados obtenidos confirman lo que habíamos observado visualmente en la Figura 1.

La correlación entre la precipitación y el rendimiento es muy elevada, lo que indica una fuerte asociación lineal entre ambas variables.

Asimismo, el coeficiente de determinación (R^2) muestra que el modelo de Regresión Lineal explica prácticamente toda la variabilidad presente en el rendimiento del cultivo.

Los valores reducidos del RMSE y del MAE indican que las diferencias entre los valores observados y las predicciones del modelo son pequeñas.

En conjunto, estas métricas respaldan una conclusión importante:

Cuando un fenómeno puede describirse mediante una relación esencialmente lineal, la estadística tradicional continúa siendo una herramienta altamente efectiva para comprender y predecir el comportamiento del sistema.

Sin embargo, este resultado corresponde a un escenario deliberadamente simple.

La verdadera pregunta es:

¿Qué ocurrirá cuando el rendimiento ya no dependa únicamente de la precipitación?

Una única variable explica prácticamente todo el fenómeno.

Existe una relación lineal muy fuerte.

La Regresión Lineal representa adecuadamente el comportamiento del cultivo.

En este escenario el uso de algoritmos más complejos probablemente no aporte mejoras significativas.

8.7 ¿Qué aprendió la Regresión Lineal?

La Regresión Lineal intenta describir la relación entre la precipitación y el rendimiento mediante una ecuación sencilla.

En otras palabras, busca responder una pregunta muy concreta:

¿Cómo cambia el rendimiento del cultivo cuando aumenta la precipitación?

Para ello ajusta una línea recta que representa la tendencia promedio observada en los datos.

Veamos cuál es la ecuación obtenida para este experimento.

```
[7]: # =====  
# Ecuación del modelo de Regresión Lineal  
# =====  
  
pendiente = modelo_lr.coef_[0]  
intercepto = modelo_lr.intercept_  
  
print("=" * 60)  
print("ECUACIÓN DEL MODELO")  
print("=" * 60)  
  
print(f"Intercepto : {intercepto:.4f}")  
print(f"Pendiente   : {pendiente:.6f}")  
  
print("\nEcuación estimada:")  
  
print(  

```

```
f"Rendimiento = {intercepto:.4f} + "  
f"({pendiente:.6f} × Precipitación)"  
)
```

```
=====
```

ECUACIÓN DEL MODELO

```
=====
```

Intercepto : 2.1811
Pendiente : 0.007862

Ecuación estimada:
 $\text{Rendimiento} = 2.1811 + (0.007862 \times \text{Precipitación})$

8.8 Una observación interesante

La ecuación obtenida es muy similar a la utilizada para construir el conjunto de datos sintéticos.

Esto era justamente lo que esperábamos.

Recordemos que este primer experimento fue diseñado deliberadamente para representar una relación prácticamente lineal entre la precipitación y el rendimiento.

Por esa razón, la Regresión Lineal consigue recuperar con gran precisión el comportamiento del sistema.

En otras palabras, el modelo está aprendiendo correctamente la lógica con la que fue construido el experimento.

Hasta este punto, no existe ninguna evidencia que justifique utilizar modelos más complejos.

Y precisamente esa es una de las principales enseñanzas de este primer escenario.

9 Aprendizajes del Experimento 1

Este primer escenario nos deja varias ideas importantes:

Una única variable puede explicar gran parte del comportamiento de un fenómeno.

Cuando la relación entre las variables es esencialmente lineal, la Regresión Lineal ofrece resultados excelentes.

La interpretación del modelo es sencilla y transparente, ya que la relación entre las variables puede expresarse mediante una ecuación.

En este tipo de problemas, utilizar modelos más complejos probablemente no aporte mejoras significativas en la capacidad predictiva.

9.1 Conclusión

La estadística tradicional continúa siendo una herramienta extraordinariamente eficaz cuando el fenómeno que estudiamos presenta relaciones simples y bien definidas.

Sin embargo, la agricultura rara vez funciona de esta manera.

La siguiente pregunta surge de forma natural:

¿Qué ocurre cuando el rendimiento del cultivo deja de depender únicamente de la precipitación?

10 =====

11 Diagnóstico Metodológico - Experimento 1

12 =====

```
diagnostico_exp1 = pd.DataFrame({
"Aspecto": [
    "Complejidad del problema",
    "Relación lineal",
    "Interpretabilidad",
    "Desempeño esperado de la Regresión Lineal",
    "Valor agregado esperado del Machine Learning"
],
"Evaluación": [
    " Baja",
    " Muy alta",
    " Muy alta",
    " Muy alto",
    " Bajo"
]
})
print("=" * 70) print("DIAGNÓSTICO METODOLÓGICO - EXPERIMENTO 1") print("=" *
70)
display(diagnostico_exp1)
```

12.1 Interpretación del diagnóstico

El primer experimento representa un escenario deliberadamente simple.

La relación entre la precipitación y el rendimiento del cultivo es prácticamente lineal y la complejidad del problema es baja.

En estas condiciones, la Regresión Lineal constituye una herramienta suficiente para describir el comportamiento observado y realizar predicciones con un alto nivel de precisión.

Desde una perspectiva metodológica, no existe evidencia que justifique el uso de algoritmos de Machine Learning más complejos.

Sin embargo, esta conclusión corresponde únicamente a este escenario.

La agricultura real rara vez depende de una sola variable.

En el siguiente experimento incorporaremos un nuevo factor que comenzará a modificar esta situación.

13 Capítulo 2

14 ¿Qué ocurre cuando una segunda variable también influye en el rendimiento del cultivo?

En el experimento anterior construimos un escenario deliberadamente simple.

La precipitación era prácticamente la única responsable del rendimiento del cultivo y, como era de esperar, la Regresión Lineal consiguió describir ese comportamiento con gran precisión.

Sin embargo, la agricultura rara vez funciona de esa manera.

Además de la lluvia, existen otros factores que también influyen en la producción agrícola.

Uno de ellos es la **materia orgánica del suelo**.

Los suelos con mayor contenido de materia orgánica suelen presentar mejores condiciones físicas, químicas y biológicas, favoreciendo el desarrollo del cultivo y su capacidad para aprovechar el agua disponible.

En este segundo experimento incorporaremos esta nueva variable.

Sin embargo, mantendremos una condición importante:

La precipitación y la materia orgánica actuarán de forma independiente.

Es decir, ambas contribuirán al rendimiento del cultivo, pero todavía no interactuarán entre sí.

Nuestro objetivo será responder la siguiente pregunta:

¿Sigue siendo suficiente la estadística tradicional cuando existen varias variables, pero sus efectos continúan siendo esencialmente lineales?

14.1 Hipótesis

Antes de construir el nuevo conjunto de datos, formularemos nuevamente una hipótesis.

Esperamos que:

- la precipitación continúe influyendo positivamente sobre el rendimiento;
- la materia orgánica también contribuya al incremento de la producción;
- ambas variables actúen de manera independiente;
- la Regresión Lineal siga describiendo correctamente el comportamiento del sistema.

En consecuencia, esperamos que la estadística tradicional continúe ofreciendo un excelente desempeño, aun cuando el problema incorpore más de una variable explicativa.

La verdadera complejidad todavía no ha aparecido.

Eso ocurrirá en los siguientes experimentos.

```
[8]: # =====  
# Generación del Dataset Sintético - Experimento 2  
# =====  
#  
# En este segundo experimento simularemos nuevamente  
# 1.000 campañas agrícolas.  
#  
# A diferencia del Experimento 1, ahora el rendimiento  
# dependerá de tres variables:  
#  
# - Precipitación  
# - Materia orgánica del suelo  
# - Temperatura media  
#  
# Todas ellas actuarán de forma independiente,  
# manteniendo una relación esencialmente lineal.  
#  
# =====  
  
import numpy as np  
import pandas as pd  
  
# -----  
# Reproducibilidad  
# -----  
  
np.random.seed(42)  
  
# -----  
# Número de campañas agrícolas simuladas  
# -----
```

```

n_campanias = 1000

# -----
# Variables explicativas
# -----

precipitacion = np.random.uniform(
    low=300,
    high=1200,
    size=n_campanias
)

materia_organica = np.random.uniform(
    low=1.0,
    high=5.0,
    size=n_campanias
)

temperatura = np.random.uniform(
    low=15,
    high=30,
    size=n_campanias
)

# -----
# Variabilidad natural
# -----

ruido = np.random.normal(
    loc=0,
    scale=0.8,
    size=n_campanias
)

# -----
# Modelo conceptual
#
# Todas las variables contribuyen al rendimiento
# de manera independiente.
# -----

rendimiento = (
    1.5
    + 0.006 * precipitacion
    + 0.90 * materia_organica
    + 0.18 * temperatura
    + ruido

```

```

)

# -----
# Construcción del DataFrame
# -----

df_exp2 = pd.DataFrame({

    "Precipitacion_mm": precipitacion,

    "Materia_Organica_pct": materia_organica,

    "Temperatura_C": temperatura,

    "Rendimiento_t_ha": rendimiento

})

# -----
# Resumen
# -----

print("=" * 65)
print("EXPERIMENTO 2 - DATASET SINTÉTICO")
print("=" * 65)

print(f"Campañas agrícolas simuladas : {len(df_exp2):,}")
print(f"Variables                      : {df_exp2.shape[1]}")

print("\nPrimeras observaciones:\n")

display(df_exp2.head())

```

```

=====
EXPERIMENTO 2 - DATASET SINTÉTICO
=====

Campañas agrícolas simuladas : 1,000
Variables                      : 4

Primeras observaciones:

    Precipitacion_mm  Materia_Organica_pct  Temperatura_C  Rendimiento_t_ha
0         637.086107         1.740532         18.925585         11.143550
1        1155.642876         3.167604         18.704682         15.145148
2         958.794548         4.491783         28.593819         16.989115
3         838.792636         3.928900         18.743193         12.349776
4         440.416776         4.226245         19.079246         12.349940

```

14.2 ¿Qué cambió respecto al experimento anterior?

En el primer experimento, el rendimiento del cultivo dependía únicamente de la precipitación.

Ahora hemos incorporado dos nuevos factores:

- la materia orgánica del suelo;
- la temperatura media durante la campaña.

Las tres variables contribuyen al rendimiento de manera independiente, manteniendo una relación lineal con la variable objetivo.

Este escenario representa una situación más cercana a la realidad agrícola, donde múltiples factores influyen simultáneamente sobre la producción.

La pregunta que intentaremos responder ahora es:

¿Sigue siendo suficiente la Regresión Lineal cuando el fenómeno depende de varias variables, pero todas ellas mantienen relaciones esencialmente lineales?

14.3 Primer vistazo al nuevo conjunto de datos

A diferencia del experimento anterior, ahora el rendimiento del cultivo depende de tres variables explicativas:

- **Precipitación**, que representa la disponibilidad de agua durante la campaña agrícola.
- **Materia orgánica**, como indicador de la calidad del suelo y su capacidad para almacenar agua y nutrientes.
- **Temperatura**, que influye sobre el desarrollo fisiológico del cultivo.

Aunque el problema es más complejo que en el Experimento 1, todavía esperamos que la Regresión Lineal describa correctamente el fenómeno, ya que las tres variables actúan de forma independiente.

Antes de construir cualquier modelo, revisaremos nuevamente la estructura y las principales características del conjunto de datos.

```
[9]: # =====  
# Exploración inicial del conjunto de datos  
# =====  
  
print("=" * 65)  
print("INFORMACIÓN GENERAL DEL DATASET")  
print("=" * 65)  
  
df_exp2.info()  
  
print("\n")  
  
print("=" * 65)  
print("ESTADÍSTICAS DESCRIPTIVAS")  
print("=" * 65)
```

```
display(df_exp2.describe().round(2))
```

=====

INFORMACIÓN GENERAL DEL DATASET

=====

```
<class 'pandas.core.frame.DataFrame'>
```

```
RangeIndex: 1000 entries, 0 to 999
```

```
Data columns (total 4 columns):
```

#	Column	Non-Null Count	Dtype
0	Precipitacion_mm	1000 non-null	float64
1	Materia_Organica_pct	1000 non-null	float64
2	Temperatura_C	1000 non-null	float64
3	Rendimiento_t_ha	1000 non-null	float64

```
dtypes: float64(4)
```

```
memory usage: 31.4 KB
```

=====

ESTADÍSTICAS DESCRIPTIVAS

=====

	Precipitacion_mm	Materia_Organica_pct	Temperatura_C	Rendimiento_t_ha
count	1000.00	1000.00	1000.00	1000.00
mean	741.23	3.03	22.54	12.73
std	262.92	1.17	4.36	2.22
min	304.17	1.01	15.00	6.24
25%	512.38	1.96	18.92	11.15
50%	747.13	3.07	22.51	12.72
75%	969.89	4.04	26.39	14.28
max	1199.75	5.00	29.97	18.84

14.4 ¿Qué nos dicen estas estadísticas?

El nuevo conjunto de datos presenta tres variables explicativas con rangos coherentes para un escenario agrícola simplificado.

Cada una aporta información distinta sobre las condiciones del cultivo:

- la precipitación representa el componente climático relacionado con el agua;
- la materia orgánica caracteriza parte de la calidad del suelo;
- la temperatura refleja las condiciones térmicas de la campaña.

En esta etapa todavía no analizamos cómo se relacionan entre sí.

Ese será precisamente el siguiente paso.

```
[10]: # =====
# Figura 2
# Matriz de correlación
```

```

# =====

import matplotlib.pyplot as plt
import seaborn as sns

corr = df_exp2.corr(numeric_only=True)

plt.figure(figsize=(8, 6))

sns.heatmap(
    corr,
    annot=True,
    fmt=".2f",
    cmap="YlGn",
    linewidths=0.5,
    square=True,
    cbar_kws={"shrink": 0.8}
)

plt.title(
    "Figura 2. Relaciones entre las variables del experimento",
    fontsize=15,
    weight="bold",
    pad=15
)


plt.figtext(
    0.5,
    -0.04,
    "Datos sintéticos generados en Python • Elaboración propia",
    ha="center",
    fontsize=10,
    color="gray"
)

plt.tight_layout()

plt.show()

```

Figura 2. Relaciones entre las variables del experimento



Datos sintéticos generados en Python • Elaboración propia

14.5 ¿Qué nos revela la matriz de correlación?

La matriz de correlación nos permite analizar, de manera simultánea, cómo se relacionan todas las variables del experimento.

A partir de los resultados obtenidos podemos realizar varias observaciones importantes:

- La **precipitación** presenta una correlación positiva con el rendimiento, confirmando que una mayor disponibilidad de agua favorece la producción del cultivo.
- La **materia orgánica** también muestra una relación positiva con el rendimiento, reflejando el papel que desempeña un suelo con mejores características físicas, químicas y biológicas.
- La **temperatura** contribuye igualmente al rendimiento dentro del rango considerado en este experimento.

Un aspecto particularmente interesante es que las variables explicativas presentan una correlación muy baja entre sí.

Esto no es una casualidad.

El experimento fue diseñado deliberadamente para que cada variable aportara información de forma independiente.

Como consecuencia, todavía no observamos relaciones complejas entre los factores que explican el rendimiento del cultivo.

Desde el punto de vista estadístico, este continúa siendo un problema relativamente ordenado y fácilmente interpretable.

```
[11]: # =====
# Figura 3
# Relación de cada variable con el rendimiento del cultivo
# =====

from sklearn.linear_model import LinearRegression
import matplotlib.pyplot as plt

# -----
# Configuración general de la figura
# -----

fig, axes = plt.subplots(
    nrows=1,
    ncols=3,
    figsize=(18,6)
)

# =====
# 1. Precipitación
# =====

X = df_exp2[["Precipitacion_mm"]]
y = df_exp2["Rendimiento_t_ha"]

modelo_lr = LinearRegression()
modelo_lr.fit(X, y)

pred_lr = modelo_lr.predict(X)

orden = X["Precipitacion_mm"].argsort()

axes[0].scatter(
    X,
    y,
    color="#2E86C1",
    alpha=0.60,
    s=28
```

```

)

axes[0].plot(
    X.iloc[orden],
    pred_lr[orden],
    color="#2E8B57",
    linewidth=2.5
)

axes[0].set_title("Precipitación")
axes[0].set_xlabel("mm")
axes[0].set_ylabel("Rendimiento (t/ha)")
axes[0].grid(alpha=0.25)

# =====
# 2. Materia Orgánica
# =====

X = df_exp2[["Materia_Organica_pct"]]

modelo_lr.fit(X, y)

pred_lr = modelo_lr.predict(X)

orden = X["Materia_Organica_pct"].argsort()

axes[1].scatter(
    X,
    y,
    color="#8E6E53",
    alpha=0.60,
    s=28
)

axes[1].plot(
    X.iloc[orden],
    pred_lr[orden],
    color="#2E8B57",
    linewidth=2.5
)

axes[1].set_title("Materia Orgánica")
axes[1].set_xlabel("%")
axes[1].grid(alpha=0.25)

# =====
# 3. Temperatura

```

```

# =====

X = df_exp2[["Temperatura_C"]]

modelo_lr.fit(X, y)

pred_lr = modelo_lr.predict(X)

orden = X["Temperatura_C"].argsort()

axes[2].scatter(
    X,
    y,
    color="#E67E22",
    alpha=0.60,
    s=28
)

axes[2].plot(
    X.iloc[orden],
    pred_lr[orden],
    color="#2E8B57",
    linewidth=2.5
)

axes[2].set_title("Temperatura")
axes[2].set_xlabel("°C")
axes[2].grid(alpha=0.25)

# =====
# Título general
# =====

fig.suptitle(
    "Figura 3. Relación individual entre las variables explicativas y el  
rendimiento",
    fontsize=16,
    fontweight="bold"
)

plt.figtext(
    0.5,
    0.01,
    "Datos sintéticos generados en Python • Elaboración propia",
    ha="center",
    fontsize=10,
    color="gray"
)


```

```
)

plt.tight_layout(rect=[0,0.04,1,0.95])

plt.show()
```

Figura 3. Relación individual entre las variables explicativas y el rendimiento



14.6 ¿Qué podemos observar en estos tres gráficos?

A diferencia del Experimento 1, donde una sola variable explicaba prácticamente todo el comportamiento del cultivo, ahora observamos que el rendimiento mantiene una relación positiva con **tres factores distintos**.

Cada gráfico muestra una tendencia aproximadamente lineal, lo que indica que cada variable aporta información útil para explicar la producción agrícola.

Aunque ninguna de ellas explica por sí sola todo el fenómeno, juntas representan una descripción más cercana a la realidad.

Este resultado es importante porque demuestra que la complejidad del problema ha aumentado, pero todavía de una forma ordenada.

Las relaciones continúan siendo esencialmente lineales, por lo que esperamos que la Regresión Lineal siga ofreciendo un excelente desempeño.

La verdadera diferencia aparecerá cuando estas variables comiencen a interactuar entre sí, situación que abordaremos en el siguiente experimento.

14.7 ¿Qué ocurre cuando analizamos todas las variables simultáneamente?

Hasta ahora hemos estudiado el efecto de cada variable por separado.

Sin embargo, en un problema agrícola real, el rendimiento no depende únicamente de un solo factor.

La precipitación, la materia orgánica y la temperatura actúan de manera simultánea.

Por esta razón, construiremos un modelo de **Regresión Lineal Múltiple**, que permitirá estimar el efecto conjunto de las tres variables sobre el rendimiento del cultivo.

La pregunta ahora es:

¿Será capaz la Regresión Lineal de mantener su excelente desempeño cuando el fenómeno depende de varias variables al mismo tiempo?

```
[12]: # =====  
# Regresión Lineal Múltiple  
# =====  
  
from sklearn.linear_model import LinearRegression  
  
# -----  
# Variables predictoras  
# -----  
  
X = df_exp2[[  
    "Precipitacion_mm",  
    "Materia_Organica_pct",  
    "Temperatura_C"  
]]  
  
# -----  
# Variable objetivo  
# -----  
  
y = df_exp2["Rendimiento_t_ha"]  
  
# -----  
# Construcción del modelo  
# -----  
  
modelo_lr = LinearRegression()  
  
modelo_lr.fit(X, y)  
  
# -----  
# Predicciones  
# -----  
  
pred_lr = modelo_lr.predict(X)
```

```
[13]: # =====  
# Coeficientes del modelo  
# =====  
  
coeficientes = pd.DataFrame({  
    "Variable": X.columns,
```

```

        "Coeficiente": modelo_lr.coef_
    })

display(coeficientes.round(4))

print("\nIntercepto:", round(modelo_lr.intercept_,4))

```

	Variable	Coeficiente
0	Precipitacion_mm	0.0059
1	Materia_Organica_pct	0.8788
2	Temperatura_C	0.1851

Intercepto: 1.5325

14.8 ¿Qué aprendió el modelo?

Los coeficientes estimados son muy próximos a los valores utilizados para construir el conjunto de datos sintéticos.

Este resultado confirma que la Regresión Lineal ha conseguido identificar correctamente la contribución individual de cada variable.

Desde un punto de vista práctico, esto significa que el modelo no solo realiza buenas predicciones, sino que además permite interpretar el efecto de cada factor sobre el rendimiento del cultivo.

Esta es una de las grandes fortalezas de la estadística tradicional cuando las relaciones entre las variables permanecen esencialmente lineales.

```

[14]: # =====
# Evaluación del modelo de Regresión Lineal Múltiple
# =====

from sklearn.metrics import (
    r2_score,
    mean_squared_error,
    mean_absolute_error
)

import numpy as np

# -----
# Métricas del modelo
# -----

r2_lr = r2_score(y, pred_lr)

rmse_lr = np.sqrt(
    mean_squared_error(y, pred_lr)
)

```

```

)

mae_lr = mean_absolute_error(y, pred_lr)

# -----
# Tabla resumen
# -----

metricas_exp2 = pd.DataFrame({

    "Métrica": [

        "R2",

        "RMSE",

        "MAE"

    ],

    "Valor": [

        r2_lr,

        rmse_lr,

        mae_lr

    ]

})

print("=" * 65)
print("DESEMPEÑO DEL MODELO - REGRESIÓN LINEAL MÚLTIPLE")
print("=" * 65)

display(metricas_exp2.round(4))

```

```

=====
DESEMPEÑO DEL MODELO - REGRESIÓN LINEAL MÚLTIPLE
=====

```

	Métrica	Valor
0	R ²	0.8692
1	RMSE	0.8020
2	MAE	0.6486

14.9 ¿Qué nos indican estas métricas?

Los resultados muestran que la Regresión Lineal Múltiple continúa describiendo el comportamiento del sistema con un alto nivel de precisión.

El coeficiente de determinación (R^2) indica que el modelo explica la mayor parte de la variabilidad observada en el rendimiento del cultivo.

Asimismo, los valores reducidos del RMSE y del MAE reflejan que las diferencias entre los valores observados y las predicciones son pequeñas.

En consecuencia, el incremento en el número de variables no ha reducido la capacidad predictiva del modelo.

¿Por qué?

Porque el problema sigue siendo esencialmente lineal.

Cada variable aporta información al rendimiento, pero lo hace de forma independiente y sin generar relaciones complejas.

En estas condiciones, la estadística tradicional continúa ofreciendo un desempeño sobresaliente.

14.10 Una reflexión antes de continuar

Hasta este momento hemos comprobado que la Regresión Lineal responde muy bien en dos escenarios diferentes:

- cuando el rendimiento depende de una sola variable;
- cuando depende de varias variables, siempre que sus efectos sean independientes y aproximadamente lineales.

Esto nos lleva a una pregunta inevitable.

La agricultura es un sistema dinámico donde los factores rara vez actúan de manera aislada.

Por ejemplo:

- una misma cantidad de lluvia puede producir resultados muy diferentes dependiendo del contenido de materia orgánica del suelo;
- una temperatura elevada puede favorecer o limitar el rendimiento según la disponibilidad de agua;
- el efecto de la fertilización puede variar dependiendo de las condiciones climáticas.

En otras palabras, las variables comienzan a interactuar entre sí.

Y cuando esto ocurre, la realidad deja de comportarse como una simple suma de efectos independientes.

Ese será precisamente el escenario que construiremos en el siguiente experimento.

15 Capítulo 3

16 ¿Qué ocurre cuando las variables comienzan a interactuar?

Hasta este momento hemos trabajado con un supuesto muy conveniente desde el punto de vista estadístico:

Cada variable aportaba información al rendimiento del cultivo de manera independiente.

Sin embargo, la naturaleza rara vez funciona de esa forma.

En un sistema agrícola real, los factores ambientales y del suelo no actúan de manera aislada.

Por el contrario, interactúan constantemente.

Por ejemplo:

- Una misma cantidad de lluvia puede producir rendimientos muy diferentes dependiendo de la materia orgánica presente en el suelo.
- Un suelo rico en materia orgánica puede almacenar mejor el agua disponible y amortiguar los efectos de un período seco.
- La temperatura puede potenciar o limitar el efecto de la precipitación según las condiciones del cultivo.

En otras palabras, el efecto de una variable comienza a depender del valor que toman las demás.

Aquí es donde la realidad empieza a alejarse de un comportamiento estrictamente lineal.

La pregunta que intentaremos responder ahora es:

¿Sigue siendo suficiente la Regresión Lineal cuando las variables ya no actúan de forma independiente?

16.1 Hipótesis del Experimento 3

En los experimentos anteriores asumimos que cada variable contribuía al rendimiento del cultivo de manera independiente.

Sin embargo, esta simplificación rara vez representa lo que ocurre en un sistema agrícola real.

En la práctica, los factores ambientales interactúan continuamente.

Por ejemplo, una determinada cantidad de lluvia puede producir un rendimiento elevado en un suelo rico en materia orgánica, pero un rendimiento mucho menor en un suelo degradado.

En este experimento incorporaremos por primera vez una **interacción entre variables**.

La precipitación continuará siendo importante.

La materia orgánica también.

La temperatura seguirá influyendo sobre el cultivo.

Pero ahora el efecto de la precipitación dependerá parcialmente del contenido de materia orgánica del suelo.

Nuestra hipótesis es la siguiente:

- La Regresión Lineal seguirá capturando una parte importante del comportamiento del cultivo.
- Sin embargo, comenzará a perder capacidad para representar completamente el fenómeno.
- La complejidad del problema aumentará, acercándonos un poco más a las condiciones que encontramos en la agricultura real.

```
[15]: # =====  
# Generación del Dataset Sintético - Experimento 3  
# =====  
#  
# En este tercer experimento simularemos nuevamente  
# 1.000 campañas agrícolas.  
#  
# A diferencia del experimento anterior, el rendimiento  
# ya no dependerá únicamente de la suma de los efectos  
# individuales de cada variable.  
#  
# Incorporaremos una interacción entre la precipitación  
# y la materia orgánica.  
#  
# Conceptualmente, esto representa que un suelo con mayor  
# contenido de materia orgánica aprovecha mejor el agua  
# disponible para el cultivo.  
#  
# Este comportamiento es frecuente en sistemas agrícolas  
# reales y constituye una primera aproximación a fenómenos  
# donde las variables dejan de actuar de forma independiente.  
# =====  
  
import numpy as np  
import pandas as pd  
  
# -----  
# Reproducibilidad  
# -----  
  
np.random.seed(42)  
  
# -----  
# Número de campañas agrícolas simuladas  
# -----  
  
n_campanias = 1000  
  
# -----  
# Variables explicativas  
# -----
```

```

precipitacion = np.random.uniform(
    low=300,
    high=1200,
    size=n_campanias
)

materia_organica = np.random.uniform(
    low=1.0,
    high=5.0,
    size=n_campanias
)

temperatura = np.random.uniform(
    low=15,
    high=30,
    size=n_campanias
)

radiacion = np.random.uniform(
    low=15,
    high=30,
    size=n_campanias
)

# -----
# Variabilidad natural
# -----

ruido = np.random.normal(
    loc=0,
    scale=0.8,
    size=n_campanias
)

# -----
# Interacción entre variables
#
# Un mayor contenido de materia orgánica mejora la capacidad
# del suelo para aprovechar la precipitación.
# -----

interaccion = (
    0.0015
    * precipitacion
    * materia_organica
)

```

```

# -----
# Modelo conceptual
# -----

rendimiento = (

    1.2

    + 0.0055 * precipitacion

    + 0.80 * materia_organica

    + 0.15 * temperatura

    + 0.05 * radiacion

    + interaccion

    + ruido

)

# -----
# Construcción del DataFrame
# -----

df_exp3 = pd.DataFrame({

    "Precipitacion_mm": precipitacion,

    "Materia_Organica_pct": materia_organica,

    "Temperatura_C": temperatura,

    "Radiacion": radiacion,

    "Rendimiento_t_ha": rendimiento

})

# -----
# Resumen del experimento
# -----

print("=" * 65)
print("EXPERIMENTO 3 - DATASET SINTÉTICO")

```

```

print("=" * 65)

print(f"Campañas agrícolas simuladas : {len(df_exp3):,}")
print(f"Variables                      : {df_exp3.shape[1]:,}")

print("\nPrimeras observaciones:\n")

display(df_exp3.head())

```

=====

EXPERIMENTO 3 - DATASET SINTÉTICO

=====

Campañas agrícolas simuladas : 1,000
Variables : 5

Primeras observaciones:

	Precipitacion_mm	Materia_Organica_pct	Temperatura_C	Radiacion	\
0	637.086107	1.740532	18.925585	25.090545	
1	1155.642876	3.167604	18.704682	26.950221	
2	958.794548	4.491783	28.593819	18.757018	
3	838.792636	3.928900	18.743193	24.373111	
4	440.416776	4.226245	19.079246	23.576190	

	Rendimiento_t_ha
0	12.915980
1	19.984808
2	21.268564
3	18.294635
4	13.468676

16.2 ¿Qué cambió realmente en este experimento?

A primera vista, el conjunto de datos parece muy similar al del Experimento 2.

Sin embargo, existe una diferencia fundamental.

En los experimentos anteriores, cada variable contribuía al rendimiento del cultivo de manera independiente.

Ahora hemos incorporado una interacción entre la precipitación y la materia orgánica.

Esto significa que el efecto de la lluvia ya no es exactamente el mismo para todas las campañas agrícolas.

Un suelo con mayor contenido de materia orgánica puede aprovechar mejor el agua disponible, mientras que un suelo degradado obtiene un beneficio menor, aun cuando ambos reciban la misma cantidad de precipitación.

Este pequeño cambio representa una situación mucho más cercana a la realidad agrícola.

A partir de este momento, el problema comienza a dejar de ser una simple suma de efectos independientes.

16.3 ¿Qué cambió realmente en este experimento?

A primera vista, el conjunto de datos parece muy similar al del Experimento 2.

Sin embargo, existe una diferencia fundamental.

En los experimentos anteriores, cada variable contribuía al rendimiento del cultivo de manera independiente.

Ahora hemos incorporado una interacción entre la precipitación y la materia orgánica.

Esto significa que el efecto de la lluvia ya no es exactamente el mismo para todas las campañas agrícolas.

Un suelo con mayor contenido de materia orgánica puede aprovechar mejor el agua disponible, mientras que un suelo degradado obtiene un beneficio menor, aun cuando ambos reciban la misma cantidad de precipitación.

Este pequeño cambio representa una situación mucho más cercana a la realidad agrícola.

A partir de este momento, el problema comienza a dejar de ser una simple suma de efectos independientes.

```
[16]: # =====
# Exploración inicial del conjunto de datos
# =====

print("=" * 65)
print("INFORMACIÓN GENERAL DEL DATASET")
print("=" * 65)

df_exp3.info()

print("\n")

print("=" * 65)
print("ESTADÍSTICAS DESCRIPTIVAS")
print("=" * 65)

display(df_exp3.describe().round(2))

=====
INFORMACIÓN GENERAL DEL DATASET
=====
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1000 entries, 0 to 999
Data columns (total 5 columns):
 #   Column              Non-Null Count  Dtype
---  -

```

```

0  Precipitacion_mm      1000 non-null   float64
1  Materia_Organica_pct  1000 non-null   float64
2  Temperatura_C         1000 non-null   float64
3  Radiacion            1000 non-null   float64
4  Rendimiento_t_ha     1000 non-null   float64
dtypes: float64(5)
memory usage: 39.2 KB

```

```

=====
ESTADÍSTICAS DESCRIPTIVAS
=====

```

	Precipitacion_mm	Materia_Organica_pct	Temperatura_C	Radiacion \
count	1000.00	1000.00	1000.00	1000.00
mean	741.23	3.03	22.54	22.36
std	262.92	1.17	4.36	4.30
min	304.17	1.01	15.00	15.01
25%	512.38	1.96	18.92	18.63
50%	747.13	3.07	22.51	22.26
75%	969.89	4.04	26.39	26.06
max	1199.75	5.00	29.97	29.99

	Rendimiento_t_ha
count	1000.00
mean	15.58
std	3.69
min	7.61
25%	12.92
50%	15.19
75%	18.08
max	25.70

16.4 ¿Qué nos indican estas estadísticas?

A primera vista, las estadísticas descriptivas no muestran diferencias evidentes respecto al Experimento 2.

Las variables continúan presentando rangos razonables y no existen valores faltantes, ya que el conjunto de datos fue generado de forma controlada.

Sin embargo, la diferencia más importante no se encuentra en los valores individuales de las variables, sino en la forma en que estas comienzan a relacionarse para explicar el rendimiento del cultivo.

Precisamente por esa razón, el siguiente paso consistirá en analizar nuevamente las relaciones entre las variables mediante una matriz de correlación.

16.5 ¿La matriz de correlación sigue siendo suficiente?

La matriz de correlación continúa siendo una herramienta muy útil para explorar los datos.

Sin embargo, comienza a mostrar una de sus principales limitaciones.

Analiza las relaciones entre pares de variables de manera independiente.


Pero no puede describir completamente situaciones donde el efecto de una variable depende del comportamiento de otra.

Veamos qué información nos proporciona en este nuevo escenario.

```
[17]: # =====  
# Figura 4  
# Matriz de correlación  
# =====  
  
import matplotlib.pyplot as plt  
import seaborn as sns  
  
corr = df_exp3.corr(numeric_only=True)  
  
plt.figure(figsize=(8,6))  
  
sns.heatmap(  
    corr,  
    annot=True,  
    fmt=".2f",  
    cmap="YlGn",  
    linewidths=0.5,  
    square=True,  
    cbar_kws={"shrink":0.8}  
)  
  
plt.title(  
    "Figura 4. Matriz de correlación - Experimento 3",  
    fontsize=15,  
    weight="bold",  
    pad=15  
)  
  
plt.figtext(  
    0.5,  
    -0.04,  
    "Datos sintéticos generados en Python • Elaboración propia",  
    ha="center",  
    fontsize=10,  
    color="gray"  
)
```

```
plt.tight_layout()
plt.show()
```

Figura 4. Matriz de correlación - Experimento 3



Datos sintéticos generados en Python • Elaboración propia

16.6 Una observación importante

La matriz de correlación continúa siendo una herramienta muy útil para explorar las relaciones entre las variables.

Sin embargo, este experimento pone de manifiesto una característica importante de los sistemas reales.

Aunque la correlación permite identificar asociaciones lineales entre pares de variables, no siempre revela completamente la estructura del fenómeno que estamos estudiando.

En este caso, el rendimiento ya no depende únicamente de los efectos individuales de la precipitación, la materia orgánica, la temperatura y la radiación.

Existe además una interacción entre algunas de estas variables.

Esta interacción forma parte del proceso que genera el rendimiento, pero no aparece explícitamente representada en la matriz de correlación.

Por esta razón, comprender un problema complejo requiere ir más allá de observar únicamente las correlaciones entre variables.

```
[18]: # =====  
# Figura 5  
# La interacción comienza a hacerse visible  
# =====  
  
import matplotlib.pyplot as plt  
  
plt.figure(figsize=(10,7))  
  
scatter = plt.scatter(  
    df_exp3["Precipitacion_mm"],  
    df_exp3["Rendimiento_t_ha"],  
    c=df_exp3["Materia_Organica_pct"],  
    cmap="YlGn",  
    alpha=0.75,  
    s=45,  
    edgecolors="white",  
    linewidth=0.3  
)  
  
cbar = plt.colorbar(scatter)  
cbar.set_label("Materia orgánica (%)")  
  
plt.title(  
    "Figura 5. El efecto de la precipitación depende del contenido de materia_  
    ↪ orgánica",  
    fontsize=15,  
    weight="bold"  
)  
  
plt.xlabel("Precipitación (mm)")  
plt.ylabel("Rendimiento (t/ha)")  
  
plt.grid(alpha=0.25)  
  
plt.figtext(  
    0.5,  
    -0.03,
```

```


    "Datos sintéticos generados en Python • Elaboración propia",
    ha="center",
    fontsize=10,
    color="gray"
)

plt.tight_layout()

plt.show()

```

Figura 5. El efecto de la precipitación depende del contenido de materia orgánica



16.7 ¿Qué nos muestra este gráfico?

En los experimentos anteriores, una misma cantidad de precipitación producía aproximadamente el mismo nivel de rendimiento.

Ahora observamos un comportamiento diferente.

Para valores similares de precipitación aparecen distintos niveles de rendimiento.

La diferencia está asociada al contenido de materia orgánica del suelo.

Los puntos con mayor contenido de materia orgánica tienden a ubicarse en los niveles superiores de rendimiento, mientras que aquellos con menor contenido se concentran en valores inferiores.

Este comportamiento refleja una situación frecuente en la agricultura.

La lluvia, por sí sola, ya no explica completamente el rendimiento del cultivo.

Su efecto depende también de las condiciones del suelo.

Es precisamente este tipo de relaciones el que comienza a aumentar la complejidad del problema.

16.8 ¿Qué ocurre si ignoramos la interacción entre las variables?

Hasta este momento sabemos que el rendimiento del cultivo depende de la precipitación, la materia orgánica, la temperatura y la radiación.

Sin embargo, construiremos inicialmente el mismo tipo de modelo utilizado en el experimento anterior.

Es decir, asumiremos que todas las variables actúan de forma independiente.

Esta decisión es completamente deliberada.

Nuestro objetivo es observar hasta qué punto un modelo lineal tradicional continúa representando adecuadamente un fenómeno cuya complejidad ha comenzado a aumentar.

```
[19]: # =====  
# Regresión Lineal Múltiple  
# (sin considerar explícitamente la interacción)  
# =====  
  
from sklearn.linear_model import LinearRegression  
  
# -----  
# Variables predictoras  
# -----  
  
X = df_exp3[[  
    "Precipitacion_mm",  
    "Materia_Organica_pct",  
    "Temperatura_C",  
    "Radiacion"  
]]  
  
# -----  
# Variable objetivo  
# -----  
  
y = df_exp3["Rendimiento_t_ha"]  
  
# -----  
# Construcción del modelo  
# -----
```

```

modelo_lr = LinearRegression()

modelo_lr.fit(X, y)

# -----
# Predicciones
# -----

pred_lr = modelo_lr.predict(X)

```

```

[20]: # =====
# Coeficientes del modelo
# =====

coeficientes = pd.DataFrame({

    "Variable":X.columns,

    "Coeficiente":modelo_lr.coef_

})

display(
    coeficientes.round(4)
)

print("\nIntercepto:",round(modelo_lr.intercept_,4))

```

	Variable	Coeficiente
0	Precipitacion_mm	0.0099
1	Materia_Organica_pct	1.9191
2	Temperatura_C	0.1545
3	Radiacion	0.0396

Intercepto: -1.9685

```

[21]: # =====
# Evaluación del modelo
# =====

from sklearn.metrics import (
    r2_score,
    mean_squared_error,
    mean_absolute_error
)

import numpy as np

```

```

# -----
# Métricas
# -----

r2_lr = r2_score(y, pred_lr)

rmse_lr = np.sqrt(
    mean_squared_error(y, pred_lr)
)

mae_lr = mean_absolute_error(y, pred_lr)

# -----
# Tabla resumen
# -----

metricas_exp3 = pd.DataFrame({

    "Métrica":[
        "R2",
        "RMSE",
        "MAE"
    ],

    "Valor":[
        r2_lr,
        rmse_lr,
        mae_lr
    ]

})

print("="*65)
print("DESEMPEÑO DEL MODELO - REGRESIÓN LINEAL")
print("="*65)

display(metricas_exp3.round(4))

```

```

=====
DESEMPEÑO DEL MODELO - REGRESIÓN LINEAL
=====

```

	Métrica	Valor
0	R ²	0.9366
1	RMSE	0.9296
2	MAE	0.7389

16.9 ¿Qué nos enseñan estos resultados?

El modelo de Regresión Lineal continúa mostrando un desempeño muy elevado, incluso después de incorporar una primera interacción entre variables.

Este resultado es importante porque demuestra que la presencia de una interacción no implica, por sí sola, que un modelo lineal deje de ser útil.

En este experimento, la interacción entre la precipitación y la materia orgánica representa una situación más cercana a la realidad agrícola. Sin embargo, su influencia todavía puede ser aproximada razonablemente mediante un modelo lineal.

En otras palabras, la complejidad del sistema ha comenzado a aumentar, pero aún no es suficiente para justificar el uso de modelos más sofisticados.

Esta observación constituye una enseñanza importante para la Ciencia de Datos:

La elección de un modelo no debe basarse en la cantidad de variables ni en la presencia aislada de una interacción, sino en la capacidad del modelo para representar adecuadamente el comportamiento del fenómeno que se desea comprender y predecir.

El verdadero desafío aparecerá en el siguiente experimento, donde incorporaremos relaciones más complejas y patrones que ya no podrán describirse adecuadamente mediante una aproximación lineal.

17 Capítulo 4

18 ¿Qué ocurre cuando el sistema agrícola se comporta como en la realidad?

Hasta ahora hemos incrementado gradualmente la complejidad del problema.

Primero analizamos un cultivo cuyo rendimiento dependía de una sola variable.

Después incorporamos nuevos factores que actuaban de manera independiente.

Finalmente introdujimos una primera interacción entre la precipitación y la materia orgánica.

Sin embargo, los sistemas agrícolas reales son considerablemente más complejos.

Las variables no solo interactúan entre sí.

También presentan respuestas no lineales, efectos de saturación, valores óptimos y comportamientos que cambian dependiendo del contexto.

En este último experimento construiremos un escenario inspirado en el funcionamiento de un sistema agrícola real.

Nuestro objetivo ya no será únicamente explicar el rendimiento del cultivo.

Ahora queremos responder una pregunta más profunda:

¿En qué momento la complejidad del fenómeno comienza a superar la capacidad de un modelo lineal?

19 Antes de construir el modelo...

Hasta este momento hemos incrementado gradualmente la complejidad del problema.

Primero analizamos un cultivo cuyo rendimiento dependía únicamente de la precipitación.

Posteriormente incorporamos nuevas variables que actuaban de manera independiente.

Más adelante introdujimos una primera interacción entre la precipitación y la materia orgánica.

Sin embargo, un sistema agrícola real es mucho más complejo.

La respuesta de un cultivo no depende únicamente de la cantidad de lluvia recibida ni de una sola característica del suelo.

Depende de la interacción simultánea entre numerosos procesos físicos, químicos y biológicos.

Por ejemplo:

- La materia orgánica mejora la capacidad del suelo para retener agua.
- El riego puede compensar parcialmente un déficit de precipitación.
- La temperatura posee un rango óptimo para el desarrollo del cultivo.
- Un pH inadecuado reduce la disponibilidad de nutrientes.
- La fertilización presenta rendimientos decrecientes.
- La radiación condiciona la fotosíntesis, pero su efecto depende de la disponibilidad de agua.

En consecuencia, dos campañas agrícolas pueden recibir exactamente la misma cantidad de lluvia y, sin embargo, obtener rendimientos completamente diferentes.

No porque exista un error en los datos.

Sino porque el sistema agrícola responde como un conjunto de procesos interdependientes.

Esa es precisamente la realidad que intentaremos representar en este último experimento.

19.1 Un cambio de perspectiva

En los experimentos anteriores construimos modelos a partir de variables.

Ahora construiremos un modelo a partir del funcionamiento del sistema agrícola.

La diferencia puede parecer sutil, pero es fundamental.

En un sistema real, las variables no existen de forma aislada.

Forman parte de procesos que interactúan continuamente.

Por esta razón, el objetivo ya no consiste únicamente en describir relaciones estadísticas.

Nuestro objetivo es aproximarnos al comportamiento del sistema.

Y cuando la complejidad del sistema aumenta, también aumenta la necesidad de utilizar modelos capaces de representar esa complejidad.

20 Modelo conceptual del sistema agrícola

Antes de construir el conjunto de datos sintético, es importante comprender cómo imaginamos el funcionamiento del cultivo.

El objetivo de este experimento no consiste en reproducir un cultivo específico, sino representar de forma simplificada algunos de los procesos que normalmente ocurren en los sistemas agrícolas.

Las relaciones consideradas responden a principios agronómicos ampliamente conocidos.

20.1 1. Disponibilidad de agua

La lluvia constituye la principal fuente de agua para el cultivo.

Sin embargo, su efecto depende de otros factores como el riego y la capacidad del suelo para retener humedad.

20.2 2. Materia orgánica

Un suelo con mayor contenido de materia orgánica presenta una mejor estructura, mayor capacidad de retención de agua y una disponibilidad más estable de nutrientes.

Como consecuencia, una misma precipitación puede generar respuestas diferentes según las condiciones del suelo.

20.3 3. Temperatura

El crecimiento del cultivo responde a un rango óptimo de temperatura.

Temperaturas demasiado bajas o demasiado altas reducen el rendimiento.

20.4 4. pH del suelo

La disponibilidad de nutrientes alcanza su máximo dentro de un intervalo de pH.

Fuera de ese rango, la eficiencia nutricional disminuye.

20.5 5. Fertilización

La respuesta del cultivo aumenta inicialmente con la fertilización.

Sin embargo, a partir de cierto punto aparecen rendimientos decrecientes.

20.6 6. Radiación solar

La radiación aporta energía para la fotosíntesis.

Su efecto es positivo, pero depende también de la disponibilidad de agua y nutrientes.

20.7 Conclusión

El rendimiento del cultivo surge de la interacción simultánea de múltiples procesos.

Precisamente esa complejidad constituye el escenario donde el Machine Learning comienza a aportar un mayor valor.

20.8 Reflexión metodológica

No elegimos Machine Learning porque sea más moderno.

Lo elegimos porque el fenómeno que queremos comprender ya no puede describirse adecuadamente mediante relaciones lineales simples.

21 Arquitectura Conceptual del Sistema Agrícola

Antes de generar el conjunto de datos sintético, definiremos el comportamiento del sistema que deseamos representar.

Este paso es fundamental.

En Ciencia de Datos, un modelo predictivo solo será tan bueno como la comprensión que tengamos del fenómeno que intenta describir.

Por esta razón, antes de escribir una sola línea de código responderemos una pregunta esencial:

¿Cómo funciona realmente el sistema agrícola que queremos modelar?

En este experimento asumiremos que el rendimiento del cultivo depende de la interacción entre diversos procesos físicos, químicos y biológicos.

Cada uno aportará información diferente al comportamiento final del sistema.

El objetivo no consiste en reproducir un cultivo específico, sino representar de manera simplificada la complejidad que caracteriza a muchos sistemas agrícolas reales.

22 Reglas que gobiernan el sistema agrícola

Para construir el conjunto de datos sintético estableceremos un conjunto de reglas inspiradas en principios agronómicos.

Estas reglas representan el conocimiento del dominio que posteriormente será traducido a un modelo matemático.

22.1 Regla 1

La precipitación constituye la principal fuente de agua para el cultivo.

22.2 Regla 2

El riego puede compensar parcialmente un déficit de precipitación.

22.3 Regla 3

La materia orgánica mejora la capacidad del suelo para retener humedad y aumenta la eficiencia en el aprovechamiento del agua.

22.4 Regla 4

La temperatura presenta un rango óptimo para el desarrollo del cultivo.

Fuera de ese intervalo el rendimiento disminuye.

22.5 Regla 5

El pH posee un intervalo óptimo donde la disponibilidad de nutrientes es máxima.

22.6 Regla 6

La fertilización incrementa el rendimiento, pero presenta rendimientos decrecientes.

22.7 Regla 7

La radiación favorece la fotosíntesis, aunque su efecto depende de la disponibilidad de agua y nutrientes.

Estas reglas no representan un cultivo específico.

Representan un comportamiento agronómico simplificado que utilizaremos para construir un escenario suficientemente complejo para evaluar distintos modelos predictivos.

Precipitación

Agua disponible

Riego

Humedad del suelo

Materia Orgánica

Eficiencia hídrica

Temperatura óptima

pH óptimo

Fertilización

23 Del conocimiento agronómico al modelo matemático

Las reglas definidas en la sección anterior representan el comportamiento esperado del sistema agrícola.

El siguiente paso consiste en traducir esas reglas a expresiones matemáticas simplificadas.

Cada expresión representará un proceso específico del sistema.

Posteriormente, todos esos procesos se integrarán para generar el rendimiento final del cultivo.

Este enfoque reproduce la lógica utilizada en numerosos proyectos de Ciencia de Datos aplicada, donde el conocimiento del dominio constituye el punto de partida para la construcción de modelos predictivos.

```
[22]: # =====
# Generación del Dataset Sintético - Experimento 4
# =====
#
# En este experimento construiremos un sistema agrícola
# inspirado en procesos reales.
#
# El objetivo no consiste en representar un cultivo
# específico, sino simular un escenario donde múltiples
# procesos interactúan de manera simultánea.
#
# =====

import numpy as np
import pandas as pd

# -----
# Reproducibilidad
# -----

np.random.seed(42)

# -----
# Número de campañas agrícolas simuladas
# -----

n_campanias = 1000
```

```

# -----
# Variables climáticas
# -----

precipitacion = np.random.uniform(
    250,
    1200,
    n_campanias
)

temperatura = np.random.uniform(
    12,
    35,
    n_campanias
)

radiacion = np.random.uniform(
    15,
    30,
    n_campanias
)

# -----
# Variables del suelo
# -----

materia_organica = np.random.uniform(
    1,
    6,
    n_campanias
)

ph = np.random.uniform(
    4.8,
    8.2,
    n_campanias
)

# -----
# Variables de manejo
# -----

fertilizacion = np.random.uniform(
    50,
    250,
    n_campanias
)

```

```

)

riego = np.random.uniform(
    0,
    300,
    n_campanias
)

print("="*65)
print("VARIABLES BASE GENERADAS")
print("="*65)

print(f"Campañas simuladas : {n_campanias:,}")

print("\nVariables disponibles:")

print("""
    Precipitación
    Temperatura
    Radiación
    Materia Orgánica
    pH
    Fertilización
    Riego
""")

```

```

=====
VARIABLES BASE GENERADAS
=====
Campañas simuladas : 1,000

Variables disponibles:

    Precipitación
    Temperatura
    Radiación
    Materia Orgánica
    pH
    Fertilización
    Riego

```

24 Primer paso: definir el contexto del sistema

Las variables anteriores representan algunos de los principales factores que condicionan el rendimiento de un cultivo.

Sin embargo, ninguna de ellas determina por sí sola la producción agrícola.

El rendimiento surge de la interacción entre estas variables.

Por esta razón, antes de calcular la producción del cultivo construiremos varios procesos intermedios que representarán el funcionamiento simplificado del sistema agrícola.

En otras palabras, no modelaremos directamente el rendimiento.

Modelaremos primero los procesos que lo generan.

```
[23]: # =====  
# Proceso 1  
# Disponibilidad de agua  
# =====  
#  
# La disponibilidad de agua depende principalmente  
# de la precipitación y del riego suplementario.  
#  
# Se asume que el riego compensa parcialmente  
# los déficits de precipitación.  
# =====  
  
agua_disponible = (  
    precipitacion  
    + 0.60 * riego  
)
```

24.1 Proceso 1: Disponibilidad de agua

La lluvia constituye la principal fuente de agua para el cultivo.

Sin embargo, en numerosos sistemas agrícolas el riego suplementario permite reducir parcialmente los efectos de un déficit hídrico.

Por esta razón, en este experimento la disponibilidad de agua será el resultado combinado de ambos componentes.

Este proceso representa una simplificación del balance hídrico que normalmente condiciona el desarrollo del cultivo.

24.2 Proceso 2: Eficiencia en el aprovechamiento del agua

No toda el agua disponible es utilizada de la misma manera por el cultivo.

La capacidad del suelo para almacenar y suministrar agua depende, entre otros factores, de su contenido de materia orgánica.

Los suelos con mayor materia orgánica presentan una mejor estructura, mayor porosidad y una mayor capacidad para retener humedad.

Como consecuencia, una misma cantidad de agua puede producir respuestas diferentes según las condiciones del suelo.

En este experimento representaremos este comportamiento mediante un índice simplificado de eficiencia hídrica.

```
[24]: # =====
# Proceso 2
# Eficiencia en el aprovechamiento del agua
# =====

# La materia orgánica mejora la estructura del suelo
# y aumenta la eficiencia con la que el cultivo utiliza
# el agua disponible.

eficiencia_hidrica = (

    1

    + 0.20 * np.log1p(materia_organica)

)

print("="*60)
print("EFICIENCIA HÍDRICA")
print("="*60)

print(f"Valor mínimo : {eficiencia_hidrica.min():.3f}")
print(f"Valor medio   : {eficiencia_hidrica.mean():.3f}")
print(f"Valor máximo   : {eficiencia_hidrica.max():.3f}")

=====
EFICIENCIA HÍDRICA
=====

Valor mínimo : 1.139
Valor medio   : 1.287
Valor máximo   : 1.389
```

```
[25]: 1 + 0.12 * materia_organica
```

```
[25]: array([1.5236218 , 1.59800884, 1.27028074, 1.49492446, 1.46304759,
        1.61969823, 1.66365224, 1.12729406, 1.52441195, 1.15110148,
        1.4493152 , 1.29257964, 1.30406596, 1.3317751 , 1.49277547,
        1.32042998, 1.55961943, 1.36271643, 1.16101192, 1.59025591,
        1.29145499, 1.37966013, 1.53126633, 1.31947369, 1.15395139,
        1.34435263, 1.68666915, 1.50504064, 1.52288749, 1.49936929,
        1.23939528, 1.37100032, 1.57056388, 1.18082374, 1.28671167,
        1.28579147, 1.37921136, 1.70822124, 1.16050153, 1.4312206 ,
        1.22761881, 1.70240593, 1.1879821 , 1.3621606 , 1.56273099,
        1.54273266, 1.37363718, 1.3279145 , 1.35856743, 1.27856576,
        1.24319976, 1.40982382, 1.28112025, 1.292477 , 1.51405364,
```

1.7011224 , 1.48218232, 1.16618768, 1.16535017, 1.69085393,
1.29837447, 1.17524019, 1.47942675, 1.49418927, 1.50910289,
1.28044122, 1.12906641, 1.69900922, 1.27053583, 1.52561577,
1.54397792, 1.48600445, 1.30774444, 1.28265775, 1.47860097,
1.63965738, 1.68804024, 1.18354348, 1.21289717, 1.68684176,
1.56192114, 1.64979629, 1.24157958, 1.47255152, 1.54068376,
1.52806713, 1.36489101, 1.12923694, 1.46975563, 1.27186092,
1.39015255, 1.69454861, 1.35942119, 1.62388096, 1.23312436,
1.5234763 , 1.70620417, 1.18113586, 1.12499197, 1.38014968,
1.17557529, 1.56903061, 1.6687292 , 1.38041258, 1.27522699,
1.38064199, 1.55406869, 1.1254325 , 1.47367239, 1.48797501,
1.50261295, 1.26521325, 1.54843163, 1.17483489, 1.2395622 ,
1.64648203, 1.56323389, 1.12824733, 1.26902576, 1.24864389,
1.2824838 , 1.26853586, 1.15751578, 1.39536431, 1.55964008,
1.48403903, 1.523723 , 1.16868951, 1.69089443, 1.6230951 ,
1.60305419, 1.61379028, 1.6796263 , 1.44655238, 1.24016921,
1.49007016, 1.5657289 , 1.56275044, 1.43286941, 1.16107523,
1.34266776, 1.67245997, 1.47066935, 1.44299917, 1.28131211,
1.34106935, 1.65720765, 1.51987783, 1.59243222, 1.39260725,
1.49814833, 1.26903017, 1.5432765 , 1.3765608 , 1.38552731,
1.50959339, 1.68176837, 1.15840381, 1.61484594, 1.29542987,
1.38635167, 1.133148 , 1.30062765, 1.42157875, 1.15370565,
1.41465744, 1.67626638, 1.18323593, 1.57866444, 1.36580263,
1.51310423, 1.27614196, 1.21569536, 1.21627757, 1.16229517,
1.23138802, 1.51853163, 1.64901437, 1.60847541, 1.53108059,
1.18625912, 1.29351247, 1.30588413, 1.26997417, 1.4290034 ,
1.44133229, 1.33413159, 1.3322735 , 1.61713336, 1.59357571,
1.3046775 , 1.66827307, 1.69168901, 1.31604553, 1.33265497,
1.42338049, 1.68467249, 1.64579166, 1.18154078, 1.35563845,
1.45202271, 1.42187948, 1.23631784, 1.63529006, 1.52616447,
1.62274502, 1.63525857, 1.56901351, 1.38352636, 1.48632805,
1.21621924, 1.52418725, 1.22755195, 1.53636975, 1.2577589 ,
1.19053078, 1.21917069, 1.12119528, 1.55124377, 1.55944063,
1.42896001, 1.21681768, 1.1701326 , 1.13147738, 1.21944891,
1.65451332, 1.26492211, 1.3325628 , 1.18320729, 1.25341678,
1.43153474, 1.48465161, 1.26721139, 1.1546393 , 1.35461972,
1.26052202, 1.25173235, 1.69591768, 1.48978029, 1.45412707,
1.36946506, 1.3773666 , 1.444543 , 1.53785788, 1.54128766,
1.22301634, 1.42006765, 1.36717486, 1.64231618, 1.49885135,
1.43950244, 1.18923679, 1.48338273, 1.19032234, 1.32232395,
1.20570518, 1.53524419, 1.24375127, 1.35511562, 1.65740487,
1.24258983, 1.42468304, 1.371563 , 1.13087442, 1.59565487,
1.16142754, 1.40455301, 1.45640698, 1.49705587, 1.53317898,
1.27196343, 1.12598727, 1.5540662 , 1.44139396, 1.62167062,
1.61283302, 1.6259957 , 1.4110568 , 1.32017704, 1.59493492,
1.39077647, 1.23006532, 1.63298441, 1.64953593, 1.39978585,
1.16541984, 1.35269565, 1.6021226 , 1.66106442, 1.24208365,

1.16018417, 1.64641027, 1.35364296, 1.44505658, 1.70083949,
1.15993884, 1.5089908 , 1.16446325, 1.34528136, 1.60228873,
1.38008334, 1.71830941, 1.45543557, 1.31269729, 1.2520668 ,
1.33031232, 1.34351996, 1.16122821, 1.34174452, 1.39854311,
1.55364265, 1.51403769, 1.54525939, 1.12501821, 1.25060044,
1.51701057, 1.41039362, 1.12318809, 1.60269679, 1.58368574,
1.4490515 , 1.159878 , 1.57990903, 1.47022815, 1.58917599,
1.5710482 , 1.60180124, 1.43080484, 1.20419471, 1.52269448,
1.49228427, 1.56535191, 1.2219286 , 1.23698512, 1.65424571,
1.56998668, 1.66493709, 1.57522919, 1.47829318, 1.51247964,
1.65347675, 1.46728405, 1.49943479, 1.21388603, 1.40435273,
1.54983827, 1.28256562, 1.24135251, 1.30829608, 1.26490038,
1.24894758, 1.37491051, 1.66470311, 1.42423579, 1.23275223,
1.166183 , 1.53769369, 1.34967926, 1.61309857, 1.51570646,
1.59774487, 1.28316762, 1.53541535, 1.27843719, 1.68344109,
1.50182457, 1.31470708, 1.28170712, 1.23455595, 1.53678458,
1.25122937, 1.47718196, 1.27878102, 1.51718137, 1.60896384,
1.58681515, 1.5765108 , 1.23263344, 1.17303097, 1.5393693 ,
1.34100833, 1.37940774, 1.13868946, 1.27574587, 1.14020584,
1.64751146, 1.26603801, 1.4544023 , 1.14338759, 1.52010843,
1.31381641, 1.65875151, 1.65287091, 1.31517437, 1.66057654,
1.7176946 , 1.6152494 , 1.62692281, 1.26940524, 1.46602144,
1.16035355, 1.17695076, 1.71933557, 1.31598355, 1.56891035,
1.60399903, 1.63481396, 1.71857698, 1.26489789, 1.1442105 ,
1.36671491, 1.1980484 , 1.13345553, 1.3362561 , 1.59024295,
1.45970841, 1.30766679, 1.5126052 , 1.25921091, 1.12862887,
1.57861203, 1.49424585, 1.57738157, 1.14336281, 1.62227178,
1.49171572, 1.45803721, 1.49476843, 1.63865995, 1.4721619 ,
1.46857023, 1.71440749, 1.5740381 , 1.38537628, 1.5444382 ,
1.35353828, 1.25732528, 1.47811113, 1.67690926, 1.67748371,
1.32514317, 1.43660648, 1.24698154, 1.71737867, 1.70867074,
1.50970536, 1.60264844, 1.5490601 , 1.47589493, 1.1520088 ,
1.39285861, 1.52487178, 1.52651897, 1.34387357, 1.68501519,
1.22041422, 1.42021567, 1.53453039, 1.53828148, 1.50918337,
1.28517293, 1.21372394, 1.5015642 , 1.47958127, 1.22761361,
1.54308349, 1.3931032 , 1.52065635, 1.62242025, 1.22183706,
1.13148692, 1.58746155, 1.48581846, 1.53978374, 1.62289298,
1.60168656, 1.69655209, 1.44156105, 1.41309738, 1.36113232,
1.21221463, 1.46356434, 1.28620751, 1.67278451, 1.46991448,
1.47570411, 1.3329548 , 1.15119361, 1.13904626, 1.37400109,
1.17073923, 1.48410817, 1.6485838 , 1.64974889, 1.51542725,
1.2467391 , 1.6377981 , 1.65165606, 1.23799215, 1.56245565,
1.29191173, 1.60158419, 1.71834274, 1.1380156 , 1.65841952,
1.49357832, 1.70402957, 1.39900571, 1.62843276, 1.15743644,
1.32116743, 1.16020992, 1.70520588, 1.61018434, 1.63152845,
1.68277914, 1.17106209, 1.35135856, 1.16262093, 1.24647586,
1.25761947, 1.40146433, 1.2811373 , 1.18058686, 1.22049465,

1.20836534, 1.70384608, 1.5755755 , 1.70065688, 1.38384429,
1.28702109, 1.59897592, 1.31575235, 1.29963002, 1.2595036 ,
1.19780739, 1.27387784, 1.33319185, 1.52439652, 1.15753891,
1.24630416, 1.60541418, 1.20815315, 1.32558709, 1.63879535,
1.21295519, 1.1696421 , 1.4107228 , 1.30145171, 1.45804502,
1.60228293, 1.20228909, 1.46841945, 1.42330526, 1.20644727,
1.49439909, 1.28418425, 1.41270059, 1.16936339, 1.39575043,
1.30387808, 1.61342873, 1.15418724, 1.37116436, 1.39505885,
1.55500365, 1.46457255, 1.5203274 , 1.58622957, 1.63732178,
1.3083253 , 1.44281362, 1.62406485, 1.71367068, 1.65371159,
1.34288036, 1.23709991, 1.41363552, 1.56498487, 1.41554144,
1.40990852, 1.62293825, 1.33684227, 1.6358768 , 1.36408288,
1.31693986, 1.39239395, 1.57746818, 1.19560122, 1.23785153,
1.6908669 , 1.22529498, 1.46063639, 1.46758868, 1.41377468,
1.50684715, 1.25789604, 1.45159736, 1.34330395, 1.51700036,
1.20473413, 1.46252645, 1.23116221, 1.28718584, 1.25122588,
1.22970267, 1.61542657, 1.29142454, 1.67627427, 1.70195592,
1.46275628, 1.20580067, 1.34472895, 1.59863936, 1.34043444,
1.17221033, 1.45407095, 1.62707251, 1.59755583, 1.22507388,
1.52365877, 1.25230256, 1.25092452, 1.64444306, 1.26980137,
1.27794841, 1.12039203, 1.64240142, 1.59555689, 1.49639736,
1.57015946, 1.21122914, 1.39499416, 1.33073163, 1.17626592,
1.41167829, 1.67244379, 1.14403547, 1.29487655, 1.24452456,
1.26288799, 1.66506073, 1.40084143, 1.39977965, 1.57634539,
1.21269532, 1.41235921, 1.37799113, 1.47814641, 1.71973462,
1.58166934, 1.35871942, 1.61653183, 1.22242502, 1.13827821,
1.24266902, 1.32424693, 1.42634845, 1.48907748, 1.66636343,
1.42591241, 1.42076539, 1.15014581, 1.14094693, 1.45069598,
1.38290717, 1.62350824, 1.21640775, 1.134983 , 1.38942326,
1.26248713, 1.14976862, 1.55475897, 1.1869558 , 1.4849917 ,
1.28862985, 1.22409763, 1.34785091, 1.60086747, 1.35525615,
1.57046179, 1.19529178, 1.58366285, 1.26215999, 1.52643588,
1.45946893, 1.67748683, 1.35239351, 1.15969911, 1.13149329,
1.61611514, 1.43484138, 1.58514643, 1.26065536, 1.32705025,
1.13806232, 1.69689539, 1.52072074, 1.67992305, 1.27929784,
1.48687817, 1.52709998, 1.31052982, 1.62886554, 1.68829688,
1.65091307, 1.56344019, 1.28647881, 1.28896963, 1.69801619,
1.1261707 , 1.54962998, 1.5437477 , 1.49361372, 1.71406531,
1.30712766, 1.32398312, 1.16736364, 1.38567888, 1.27662912,
1.32603202, 1.62074307, 1.68129071, 1.23143984, 1.34350536,
1.67717834, 1.15708508, 1.17541632, 1.21767459, 1.4771277 ,
1.21028336, 1.70084583, 1.38802872, 1.42091078, 1.26799517,
1.40257615, 1.51714818, 1.57070628, 1.57232085, 1.46673467,
1.66261586, 1.61044471, 1.57422887, 1.15336331, 1.12412678,
1.24746837, 1.51811416, 1.36671849, 1.36144376, 1.65075213,
1.65733771, 1.66550516, 1.30832685, 1.53463349, 1.28297991,
1.2343659 , 1.23077947, 1.32526457, 1.37797457, 1.6185695 ,

1.19193466, 1.56095551, 1.43887295, 1.29276721, 1.41569175,
1.29996524, 1.47764917, 1.38030635, 1.21864332, 1.18994984,
1.44801741, 1.66144782, 1.32637461, 1.55980006, 1.51519681,
1.67893295, 1.61258861, 1.45996316, 1.5142183 , 1.65903188,
1.35971127, 1.31607682, 1.12648665, 1.61593064, 1.60058842,
1.18267271, 1.46611443, 1.39838902, 1.19122546, 1.70834094,
1.24881753, 1.16034051, 1.47690843, 1.56332001, 1.13946607,
1.51523058, 1.43937513, 1.18195901, 1.22351433, 1.46078458,
1.29781457, 1.68298944, 1.61124414, 1.71014032, 1.2758025 ,
1.70183418, 1.37874032, 1.32851128, 1.15020972, 1.15165915,
1.53520675, 1.3947574 , 1.25591298, 1.48838218, 1.27171487,
1.46657905, 1.33552525, 1.61413134, 1.6124177 , 1.40641024,
1.33049147, 1.33753588, 1.60342872, 1.31690769, 1.24543562,
1.17081301, 1.40001587, 1.40927926, 1.62454523, 1.25274322,
1.34859476, 1.60504344, 1.61417417, 1.35076665, 1.39547441,
1.30197153, 1.67953293, 1.19118626, 1.68024965, 1.53031987,
1.43894329, 1.13959544, 1.40535772, 1.36464886, 1.21673129,
1.51384576, 1.70269054, 1.45731329, 1.54885197, 1.16107027,
1.3706002 , 1.18981509, 1.4876775 , 1.68308929, 1.51706664,
1.16608183, 1.33279972, 1.45039803, 1.36192465, 1.62018641,
1.6088026 , 1.48709861, 1.34407477, 1.27320182, 1.18352459,
1.33293861, 1.36790351, 1.52549376, 1.51489589, 1.16206488,
1.35715559, 1.22906732, 1.21408762, 1.61638129, 1.14514913,
1.37150973, 1.22092219, 1.64759813, 1.45422431, 1.25882838,
1.42145637, 1.55889182, 1.69487081, 1.2522676 , 1.65170906,
1.68058247, 1.66985233, 1.50124861, 1.49789239, 1.36192638,
1.57143873, 1.43877641, 1.52646284, 1.37707474, 1.55889788,
1.61468291, 1.20786175, 1.61975783, 1.44417792, 1.62679955,
1.37878102, 1.34742429, 1.66903644, 1.27070156, 1.6265274 ,
1.41041234, 1.42845727, 1.30508097, 1.46382532, 1.31512672,
1.14356165, 1.28319916, 1.12382743, 1.70701287, 1.69944833,
1.35709318, 1.55702251, 1.32748366, 1.52265589, 1.60325803,
1.68805375, 1.36012737, 1.58997879, 1.27955707, 1.71419938,
1.13546176, 1.48211728, 1.51570359, 1.53282733, 1.19223255,
1.68311787, 1.22870997, 1.49365204, 1.25360565, 1.30432985,
1.44787513, 1.37031605, 1.21613536, 1.22256184, 1.37088687,
1.57436979, 1.65877879, 1.1704766 , 1.35586234, 1.18014734,
1.12995549, 1.51703121, 1.48146967, 1.21781147, 1.2602877 ,
1.13422465, 1.62096832, 1.70481436, 1.20127572, 1.25888513,
1.64104571, 1.67587828, 1.37177643, 1.15037348, 1.1436351 ,
1.46436992, 1.35573707, 1.13719146, 1.46995144, 1.12678152,
1.59242317, 1.30385969, 1.1441548 , 1.47301133, 1.35861065,
1.70428025, 1.4465192 , 1.28514351, 1.54566332, 1.2828952 ,
1.66254597, 1.34483318, 1.44992114, 1.15034386, 1.37567274,
1.61941812, 1.60338928, 1.25459114, 1.25564744, 1.61038319,
1.67823905, 1.17721655, 1.39003518, 1.32247257, 1.64241307,
1.17011495, 1.24667557, 1.571481 , 1.15077631, 1.41552123,

1.38526422, 1.32064071, 1.35674339, 1.43796435, 1.21682042])

24.3 Interpretación agronómica

La materia orgánica no actúa directamente incrementando el rendimiento del cultivo.

Su principal contribución consiste en mejorar la estructura del suelo, incrementar la capacidad de retención de agua y favorecer un suministro más estable de humedad para las raíces.

En consecuencia, un mismo volumen de agua disponible puede ser aprovechado con distinta eficiencia dependiendo de las características del suelo.

24.4 Reflexión metodológica

En muchos problemas reales, las variables no actúan directamente sobre el resultado.

Con frecuencia modifican la eficiencia de otros procesos.

Comprender estas relaciones es mucho más importante que simplemente incorporar nuevas variables al modelo.

24.5 Proceso 3: Temperatura óptima para el desarrollo del cultivo

La temperatura es uno de los factores más importantes que condicionan el crecimiento de un cultivo.

Sin embargo, su efecto rara vez es lineal.

Cada especie posee un intervalo óptimo donde los procesos fisiológicos alcanzan su máximo rendimiento.

Cuando la temperatura se aleja de ese rango, el crecimiento disminuye progresivamente.

Por esta razón, en lugar de utilizar una relación lineal, representaremos este comportamiento mediante una función que alcanza su máximo alrededor de una temperatura óptima.

```
[26]: # =====  
# Proceso 3  
# Efecto de la temperatura  
# =====  
#  
# Se asume que el cultivo presenta un rendimiento  
# máximo alrededor de los 24 °C.  
#  
# A medida que la temperatura se aleja de dicho valor,  
# el efecto positivo disminuye progresivamente.  
# =====  
  
temperatura_optima = 24  
  
efecto_temperatura = np.exp(
```

```

-((temperatura - temperatura_optima) ** 2)

/ (2 * 5 ** 2)

)

```

24.6 Interpretación agronómica

El crecimiento de un cultivo no aumenta indefinidamente con la temperatura.

Existe un intervalo donde el desarrollo fisiológico alcanza su máximo.

Temperaturas inferiores o superiores a ese rango generan distintos tipos de estrés, reduciendo el rendimiento potencial.

Este comportamiento representa uno de los ejemplos más comunes de respuesta no lineal en los sistemas agrícolas.

24.7 Reflexión metodológica

Muchos fenómenos naturales no siguen una línea recta.

En numerosas ocasiones, el comportamiento del sistema presenta valores óptimos, puntos de saturación o respuestas que cambian según el contexto.

Cuando estas características comienzan a dominar el fenómeno, resulta necesario considerar modelos capaces de representar relaciones no lineales.

24.8 Proceso 4: Disponibilidad de nutrientes en función del pH

El pH del suelo condiciona la disponibilidad de numerosos nutrientes esenciales para el crecimiento de los cultivos.

Cuando el suelo presenta valores excesivamente ácidos o alcalinos, disminuye la disponibilidad de algunos elementos minerales y aumenta el riesgo de deficiencias nutricionales.

Por esta razón, muchos cultivos presentan un intervalo de pH donde alcanzan su mayor potencial productivo.

En este experimento representaremos este comportamiento mediante una respuesta no lineal con un rango óptimo alrededor de pH 6.5.

[27]:

```

# =====
# Proceso 4
# Disponibilidad de nutrientes (efecto del pH)
# =====
#
# Se considera que la máxima disponibilidad de nutrientes
# ocurre alrededor de un pH cercano a 6.5.
#

```

```

# A medida que el pH se aleja de este valor,
# disminuye progresivamente la eficiencia nutricional.
# =====

ph_optimo = 6.5

efecto_ph = np.exp(

    -((ph - ph_optimo) ** 2)

    / (2 * 0.8 ** 2)

)

```

24.9 Interpretación agronómica

La disponibilidad de nutrientes depende, en gran medida, de las condiciones químicas del suelo.

Un pH cercano al intervalo óptimo favorece la absorción de nutrientes por las raíces.

En cambio, valores demasiado ácidos o alcalinos reducen la eficiencia nutricional y limitan el potencial productivo del cultivo.

Este comportamiento constituye otro ejemplo clásico de respuesta no lineal en los sistemas agrícolas.

24.10 Reflexión metodológica

En muchos problemas reales no basta con conocer el valor de una variable.

También es necesario comprender cómo responde el sistema frente a diferentes rangos de esa variable.

La Ciencia de Datos no consiste únicamente en analizar datos.

Consiste en representar, de la forma más fiel posible, el comportamiento del fenómeno que esos datos describen.

24.11 Proceso 5: Respuesta del cultivo a la fertilización

La fertilización constituye uno de los principales factores de manejo que influyen sobre el rendimiento agrícola.

Sin embargo, su efecto no es ilimitado.

Cuando el suelo presenta una baja disponibilidad de nutrientes, pequeñas aplicaciones de fertilizante generan incrementos importantes en la producción.

A medida que aumenta la fertilización, el beneficio adicional comienza a disminuir hasta alcanzar un punto donde nuevas aplicaciones producen mejoras cada vez menores.

Este comportamiento se conoce como **Ley de los Rendimientos Decrecientes** y representa uno de los principios más importantes de la producción agrícola.

```
[28]: # =====  
# Proceso 5  
# Respuesta del cultivo a la fertilización  
# =====  
#  
# La fertilización incrementa el rendimiento,  
# pero con rendimientos decrecientes.  
#  
# =====  
  
efecto_fertilizacion = np.log1p(fertilizacion)
```

24.12 Interpretación agronómica

La respuesta de un cultivo a la fertilización no es proporcional durante todo el rango de aplicación.

En condiciones de baja fertilidad, pequeños incrementos pueden producir aumentos significativos en el rendimiento.

Sin embargo, conforme se satisfacen los requerimientos nutricionales del cultivo, el efecto de nuevas aplicaciones disminuye progresivamente.

Este comportamiento refleja uno de los principios fundamentales de la producción agrícola sostenible.

24.13 Interpretación desde la Ciencia de Datos

Este proceso introduce una relación no lineal entre la fertilización y el rendimiento.

Un modelo lineal asume que cada unidad adicional de fertilizante produce siempre el mismo incremento en la producción.

En cambio, el comportamiento simulado refleja que el beneficio marginal disminuye conforme aumenta la fertilización.

Este tipo de relaciones suele ser representado con mayor fidelidad por modelos capaces de aprender patrones no lineales.

24.14 Reflexión metodológica

En Ciencia de Datos no basta con incorporar más variables.

También es necesario representar correctamente la forma en que cada variable influye sobre el fenómeno.

Un modelo predictivo comienza a ser útil cuando refleja el comportamiento del sistema y no únicamente la estructura de los datos.

25 Integración de los procesos agronómicos

Hasta este punto hemos modelado de forma independiente los principales procesos que intervienen en el desarrollo del cultivo.

Sin embargo, el rendimiento agrícola no depende de un único factor.

Es el resultado de la interacción simultánea entre la disponibilidad de agua, las propiedades del suelo, las condiciones climáticas y las prácticas de manejo.

El siguiente paso consiste en integrar todos estos procesos para estimar el potencial productivo del cultivo.

Cada componente aportará una fracción de información al comportamiento final del sistema.

Por esta razón, el rendimiento ya no será calculado mediante una relación lineal simple, sino mediante la combinación de procesos con significado agronómico.

```
[29]: # =====  
# Integración del sistema agrícola  
# =====  
#  
# En esta etapa integramos todos los procesos modelados  
# anteriormente para estimar el potencial productivo del  
# cultivo.  
#  
# Cada componente representa un proceso agronómico con  
# significado físico, biológico o de manejo.  
#  
# El objetivo no consiste en reproducir un cultivo  
# específico, sino construir un sistema agrícola coherente  
# donde las relaciones entre los factores sean  
# interpretables.  
# =====  
  
# -----  
# Potencial hídrico  
# -----  
#  
# La disponibilidad de agua es modulada por la eficiencia  
# con la que el suelo es capaz de almacenarla y ponerla  
# a disposición del cultivo.  
# -----  
  
potencial_hidrico = (  
    agua_disponible *  
    eficiencia_hidrica
```

```

)

# -----
# Potencial productivo
# -----
#
# El potencial hídrico es posteriormente modulado por:
#
# • Temperatura
# • pH del suelo
# • Fertilización
# • Radiación
#
# Cada uno representa un proceso independiente que afecta
# el desarrollo fisiológico del cultivo.
# -----

potencial_productivo = (

    potencial_hidrico

    * efecto_temperatura

    * efecto_ph

    * (1 + 0.15 * efecto_fertilizacion)

    + 0.30 * radiacion

)

print("="*65)
print("POTENCIAL PRODUCTIVO CALCULADO")
print("="*65)

print(f"Valor medio : {potencial_productivo.mean():.2f}")
print(f"Valor mínimo: {potencial_productivo.min():.2f}")
print(f"Valor máximo: {potencial_productivo.max():.2f}")

```

```

=====
POTENCIAL PRODUCTIVO CALCULADO
=====

```

```

Valor medio : 553.02
Valor mínimo: 15.20
Valor máximo: 2627.76

```

```
[30]: print(agua_disponible[:5])

print(eficiencia_hidrica[:5])

print(efecto_temperatura[:5])

print(efecto_ph[:5])

print(efecto_fertilizacion[:5])
```

```
[ 722.49936464 1184.20813627 1102.42526612  929.08648302  426.51440746]
[1.33592391  1.35779803  1.23587492  1.32680154  1.31615541]
[0.30156988  0.99570848  0.27117192  0.62579089  0.42388737]
[0.95426617  0.43062594  0.54266207  0.33898115  0.3292039 ]
[4.86543304  4.98146139  5.40226954  4.77913086  5.41578896]
```

26 Variabilidad natural del sistema

Hasta este momento hemos estimado el potencial productivo del cultivo a partir de diversos procesos agronómicos.

Sin embargo, ningún sistema agrícola es completamente determinístico.

Dos parcelas con condiciones aparentemente similares pueden presentar rendimientos diferentes debido a múltiples factores que no han sido representados explícitamente en este modelo.

Entre ellos pueden mencionarse diferencias genéticas, presencia de plagas, enfermedades, variabilidad espacial del suelo, manejo agronómico y otros procesos propios de los sistemas biológicos.

Por esta razón incorporaremos una pequeña variabilidad natural que permitirá obtener un rendimiento más cercano al observado en condiciones reales.

27 Variabilidad natural del sistema

Hasta este momento hemos estimado el potencial productivo del cultivo a partir de diversos procesos agronómicos.

Sin embargo, ningún sistema agrícola es completamente determinístico.

Dos parcelas con condiciones aparentemente similares pueden presentar rendimientos diferentes debido a múltiples factores que no han sido representados explícitamente en este modelo.

Entre ellos pueden mencionarse diferencias genéticas, presencia de plagas, enfermedades, variabilidad espacial del suelo, manejo agronómico y otros procesos propios de los sistemas biológicos.

Por esta razón incorporaremos una pequeña variabilidad natural que permitirá obtener un rendimiento más cercano al observado en condiciones reales.

```
[32]: # =====
# Variabilidad natural del sistema
# =====
```

```

#
# Ningún sistema agrícola responde exactamente igual,
# incluso bajo condiciones aparentemente similares.
#
# Esta variabilidad representa procesos que no han sido
# modelados explícitamente, tales como diferencias
# genéticas, manejo, plagas, enfermedades y otros
# factores inherentes a los sistemas biológicos.
# =====

np.random.seed(42)

variabilidad_natural = np.random.normal(
    loc=0,
    scale=25,
    size=n_campanias
)

rendimiento = (
    potencial_productivo
    + variabilidad_natural
)

```

27.1 Interpretación agronómica

Aunque el potencial productivo resume los principales procesos que condicionan el rendimiento del cultivo, en la práctica siempre existe una variabilidad adicional asociada a factores difíciles de medir o controlar.

Incorporar esta variabilidad permite aproximar el comportamiento del modelo a condiciones más cercanas a la realidad agrícola.

27.2 Interpretación desde la Ciencia de Datos

Los datos reales rara vez siguen una relación perfectamente determinística.

Incorporar una variabilidad controlada permite construir un conjunto de datos sintético más realista, evitando modelos excesivamente ideales que podrían conducir a conclusiones poco representativas de problemas reales.

27.3 Reflexión metodológica

Simular datos no significa generar números aleatorios.

Significa representar, de la forma más coherente posible, el comportamiento esperado de un fenómeno real.

La calidad de un conjunto de datos sintético depende mucho más del conocimiento del dominio que del algoritmo utilizado para generarlo.

27.4 Reflexión metodológica

Simular datos no significa generar números aleatorios.

Significa representar, de la forma más coherente posible, el comportamiento esperado de un fenómeno real.

La calidad de un conjunto de datos sintético depende mucho más del conocimiento del dominio que del algoritmo utilizado para generarlo.

```
[33]: # =====  
# Construcción del Dataset Final  
# Experimento 4  
# =====  
  
df_exp4 = pd.DataFrame({  
  
    # Variables climáticas  
    "Precipitacion_mm": precipitacion,  
    "Temperatura_C": temperatura,  
    "Radiacion": radiacion,  
  
    # Variables del suelo  
    "Materia_Organica_pct": materia_organica,  
    "pH": ph,  
  
    # Variables de manejo  
    "Fertilizacion_kg_ha": fertilizacion,  
    "Riego_mm": riego,  
  
    # Procesos del sistema  
    "Agua_Disponible": agua_disponible,  
    "Eficiencia_Hidrica": eficiencia_hidrica,  
    "Efecto_Temperatura": efecto_temperatura,  
    "Efecto_pH": efecto_ph,  
    "Efecto_Fertilizacion": efecto_fertilizacion,  
  
    # Potenciales  
    "Potencial_Hidrico": potencial_hidrico,  
    "Potencial_Productivo": potencial_productivo,  
  
    # Variable objetivo  
    "Rendimiento_t_ha": rendimiento
```

```

})

print("="*70)
print("DATASET FINAL DEL EXPERIMENTO 4")
print("="*70)

print(f"Número de observaciones : {len(df_exp4):,}")
print(f"Número de variables      : {df_exp4.shape[1]}")

display(df_exp4.head())

```

=====

DATASET FINAL DEL EXPERIMENTO 4

=====

Número de observaciones : 1,000

Número de variables : 15

	Precipitacion_mm	Temperatura_C	Radiacion	Materia_Organica_pct	pH \
0	605.813113	16.258057	18.925585	4.363515	6.744786
1	1153.178591	24.463722	18.704682	4.983407	7.538470
2	945.394245	32.077754	28.593819	2.252339	7.384547
3	818.725560	28.841172	18.743193	4.124370	5.323260
4	398.217708	30.550906	19.079246	3.858730	5.307448

	Fertilizacion_kg_ha	Riego_mm	Agua_Disponible	Eficiencia_Hidrica \
0	128.727104	194.477086	722.499365	1.335924
1	144.687132	51.715909	1184.208136	1.357798
2	220.909479	261.718369	1102.425266	1.235875
3	118.000877	183.934872	929.086483	1.326802
4	223.929937	47.161165	426.514407	1.316155

	Efecto_Temperatura	Efecto_pH	Efecto_Fertilizacion	Potencial_Hidrico \
0	0.301570	0.954266	4.865433	965.204174
1	0.995708	0.430626	4.981461	1607.915471
2	0.271172	0.542662	5.402270	1362.459734
3	0.625791	0.338981	4.779131	1232.713374
4	0.423887	0.329204	5.415789	561.359246

	Potencial_Productivo	Rendimiento_t_ha
0	486.158800	498.576654
1	1210.211807	1206.755200
2	371.537595	387.729808
3	454.579407	492.655154
4	147.695805	141.841970

```

[34]: # =====
# Información general del dataset
# =====

```

```

print("="*70)
print("INFORMACIÓN GENERAL")
print("="*70)

display(df_exp4.info())

print("\n")

display(df_exp4.describe().T)

```

===== INFORMACIÓN GENERAL =====

<class 'pandas.core.frame.DataFrame'>

RangeIndex: 1000 entries, 0 to 999

Data columns (total 15 columns):

#	Column	Non-Null Count	Dtype
0	Precipitacion_mm	1000 non-null	float64
1	Temperatura_C	1000 non-null	float64
2	Radiacion	1000 non-null	float64
3	Materia_Organica_pct	1000 non-null	float64
4	pH	1000 non-null	float64
5	Fertilizacion_kg_ha	1000 non-null	float64
6	Riego_mm	1000 non-null	float64
7	Agua_Disponible	1000 non-null	float64
8	Eficiencia_Hidrica	1000 non-null	float64
9	Efecto_Temperatura	1000 non-null	float64
10	Efecto_pH	1000 non-null	float64
11	Efecto_Fertilizacion	1000 non-null	float64
12	Potencial_Hidrico	1000 non-null	float64
13	Potencial_Productivo	1000 non-null	float64
14	Rendimiento_t_ha	1000 non-null	float64

dtypes: float64(15)

memory usage: 117.3 KB

None

	count	mean	std	min	25%	\
Precipitacion_mm	1000.0	715.743726	277.530494	254.400422	474.174604	
Temperatura_C	1000.0	23.661398	6.720368	12.074020	17.544708	
Radiacion	1000.0	22.536086	4.360113	15.000175	18.920265	
Materia_Organica_pct	1000.0	3.451875	1.432447	1.003267	2.209504	
pH	1000.0	6.479958	0.975154	4.800104	5.632912	
Fertilizacion_kg_ha	1000.0	149.692898	57.838961	51.236765	99.876001	

Riego_mm	1000.0	147.992652	86.920092	0.428503	72.066499
Agua_Disponible	1000.0	804.539317	283.782274	278.466194	559.842041
Eficiencia_Hidrica	1000.0	1.287275	0.069441	1.138956	1.233223
Efecto_Temperatura	1000.0	0.527168	0.318900	0.058159	0.222677
Efecto_pH	1000.0	0.573273	0.299543	0.104608	0.284828
Efecto_Fertilizacion	1000.0	4.929948	0.431627	3.955787	4.613891
Potencial_Hidrico	1000.0	1035.143779	368.706074	320.546946	716.762610
Potencial_Productivo	1000.0	553.015422	545.850505	15.195756	152.168460
Rendimiento_t_ha	1000.0	553.498723	547.978105	-13.722739	152.677299

	50%	75%	max
Precipitacion_mm	721.967008	957.103609	1199.731790
Temperatura_C	23.930880	29.490696	34.986516
Radiacion	22.509209	26.386553	29.967313
Materia_Organica_pct	3.421396	4.687704	5.997789
pH	6.481634	7.315978	8.192348
Fertilizacion_kg_ha	148.080563	197.970356	249.870060
Riego_mm	145.392907	226.939304	299.838204
Agua_Disponible	798.318396	1045.072665	1364.449334
Eficiencia_Hidrica	1.297291	1.347661	1.389119
Efecto_Temperatura	0.498762	0.846396	0.999994
Efecto_pH	0.573249	0.871717	1.000000
Efecto_Fertilizacion	5.004487	5.293156	5.524935
Potencial_Hidrico	1028.054729	1335.493734	1849.835477
Potencial_Productivo	370.656923	773.604927	2627.758308
Rendimiento_t_ha	367.458693	775.262421	2630.136098

27.5 Interpretación agronómica

El conjunto de datos integra variables climáticas, propiedades del suelo, prácticas de manejo y procesos derivados que representan el funcionamiento del sistema agrícola.

Aunque se trata de un dataset sintético, cada componente fue construido siguiendo una lógica coherente con principios agronómicos ampliamente aceptados.

27.6 Interpretación desde la Ciencia de Datos

Una de las ventajas de construir un conjunto de datos sintético es la posibilidad de conocer el mecanismo que generó la información.

Esto permite evaluar objetivamente el comportamiento de distintos modelos predictivos y comprender por qué algunos algoritmos representan mejor el fenómeno que otros.

28 Análisis Exploratorio de Datos (EDA)

Hasta este momento hemos construido un conjunto de datos sintético basado en principios agronómicos.

Antes de entrenar cualquier modelo predictivo, resulta indispensable comprender el comportamiento de la información.

El Análisis Exploratorio de Datos (EDA) constituye una de las etapas más importantes de cualquier proyecto de Ciencia de Datos.

Su objetivo no consiste únicamente en describir los datos, sino en identificar patrones, relaciones, tendencias y posibles comportamientos del sistema.

En este capítulo analizaremos el conjunto de datos desde dos perspectivas complementarias:

- Agronomía.
- Ciencia de Datos.

Solo después de comprender el fenómeno estaremos en condiciones de construir modelos predictivos.

```
[35]: # =====  
# Dimensiones del dataset  
# =====  
  
print("="*65)  
print("DIMENSIONES DEL DATASET")  
print("="*65)  
  
print(f"Observaciones : {df_exp4.shape[0]}")  
  
print(f"Variables      : {df_exp4.shape[1]}")  
  
=====
```

DIMENSIONES DEL DATASET

```
=====
```

Observaciones : 1000
Variables : 15

```
[36]: # =====  
# Valores faltantes  
# =====  
  
df_exp4.isnull().sum()
```

```
[36]: Precipitacion_mm      0  
Temperatura_C            0  
Radiacion                0  
Materia_Organica_pct    0  
pH                       0  
Fertilizacion_kg_ha      0  
Riego_mm                 0  
Agua_Disponible          0  
Eficiencia_Hidrica       0  
Efecto_Temperatura       0
```

```
Efecto_pH          0
Efecto_Fertilizacion 0
Potencial_Hidrico   0
Potencial_Productivo 0
Rendimiento_t_ha     0
dtype: int64
```

```
[37]: import matplotlib.pyplot as plt

plt.figure(figsize=(10,6))


plt.hist(
    df_exp4["Rendimiento_t_ha"],
    bins=30,
    edgecolor="black"
)

plt.title("Distribución del Rendimiento del Cultivo")

plt.xlabel("Rendimiento (t/ha)")

plt.ylabel("Frecuencia")

plt.show()
```



28.1 Interpretación agronómica

La variabilidad observada en el rendimiento refleja que el sistema agrícola responde de manera diferente bajo distintas combinaciones de factores climáticos, edáficos y de manejo.

Este comportamiento es coherente con lo que normalmente se observa en condiciones reales de producción.

28.2 Interpretación desde la Ciencia de Datos

Analizar la distribución de la variable objetivo constituye uno de los primeros pasos antes de entrenar un modelo predictivo.

Una distribución razonable sugiere que el conjunto de datos representa adecuadamente la variabilidad del fenómeno estudiado.

29 Relaciones entre las variables

Después de analizar individualmente las principales características del conjunto de datos, el siguiente paso consiste en estudiar cómo interactúan las variables entre sí.

Las relaciones entre variables permiten identificar patrones, dependencias y posibles asociaciones con la variable objetivo.

Este análisis constituye una etapa fundamental antes de construir modelos predictivos, ya que proporciona una primera aproximación al grado de complejidad del fenómeno estudiado.

```
[38]: # =====  
# Matriz de correlación  
# Variables observables  
# =====  
  
import matplotlib.pyplot as plt  
  
variables_modelo = [  
    "Precipitacion_mm",  
    "Temperatura_C",  
    "Radiacion",  
    "Materia_Organica_pct",  
    "pH",  
    "Fertilizacion_kg_ha",  
    "Riego_mm",  
    "Rendimiento_t_ha"  
]
```

```
corr = df_exp4[variables_modelo].corr()

plt.figure(figsize=(10,8))

im = plt.imshow(corr, interpolation="nearest")

plt.colorbar(im)


plt.xticks(
    range(len(corr.columns)),
    corr.columns,
    rotation=45,
    ha="right"
)

plt.yticks(
    range(len(corr.columns)),
    corr.columns
)

plt.title("Matriz de Correlación")

plt.tight_layout()

plt.show()
```



29.1 Interpretación agronómica

La matriz de correlación permite identificar qué variables presentan una asociación lineal más fuerte con el rendimiento del cultivo.

Sin embargo, una correlación baja no implica necesariamente que una variable carezca de importancia agronómica.

En muchos sistemas agrícolas, el efecto de una variable depende de la presencia o intensidad de otras, dando lugar a interacciones complejas que no pueden describirse únicamente mediante relaciones lineales.

29.2 Interpretación desde la Ciencia de Datos

La correlación de Pearson mide únicamente relaciones lineales entre variables.

Cuando el fenómeno contiene efectos no lineales o interacciones, una baja correlación

no significa que la variable no aporte información predictiva.


Precisamente en este tipo de situaciones es donde algoritmos como Random Forest o XGBoost suelen ofrecer un mejor desempeño.

29.3 Reflexión metodológica

Una de las conclusiones más importantes del Análisis Exploratorio de Datos es comprender que la ausencia de una fuerte correlación lineal no implica ausencia de información.

En problemas complejos, el valor predictivo puede surgir de la interacción entre múltiples variables, incluso cuando cada una de ellas, analizada de forma individual, presenta una relación aparentemente débil con la variable objetivo.

```
[39]: # =====  
# Precipitación vs Rendimiento  
# =====  
  
plt.figure(figsize=(9,6))  
  
plt.scatter(  
    df_exp4["Precipitacion_mm"],  
    df_exp4["Rendimiento_t_ha"],  
    alpha=0.70  
)  
  
plt.title("Precipitación vs Rendimiento")  
  
plt.xlabel("Precipitación (mm)")  
  
plt.ylabel("Rendimiento (t/ha)")  
  
plt.grid(alpha=0.3)  
  
plt.show()
```



29.4 Interpretación agronómica

La precipitación continúa siendo uno de los factores más importantes para explicar el rendimiento del cultivo.

Sin embargo, ya no es suficiente para describir completamente el comportamiento observado.

Para una misma cantidad de lluvia pueden obtenerse rendimientos muy diferentes debido a la influencia conjunta de propiedades del suelo, temperatura, radiación y prácticas de manejo.

29.5 Interpretación desde la Ciencia de Datos

La nube de puntos evidencia que la relación entre precipitación y rendimiento presenta una mayor dispersión que en los experimentos anteriores.

Esto indica que otras variables comienzan a explicar parte importante de la variabilidad observada, incrementando la complejidad del problema predictivo.

```
[40]: # =====
# Temperatura vs Rendimiento
# =====
```

```

plt.figure(figsize=(9,6))

plt.scatter(
    df_exp4["Temperatura_C"],
    df_exp4["Rendimiento_t_ha"],
    alpha=0.70,
    s=35
)

plt.title("Temperatura vs Rendimiento")


plt.xlabel("Temperatura (°C)")

plt.ylabel("Rendimiento (t/ha)")

plt.grid(alpha=0.3)

plt.show()

```



29.6 Interpretación agronómica

El rendimiento no aumenta indefinidamente con la temperatura.

Existe un rango óptimo en el cual el cultivo expresa su mayor potencial productivo.

Temperaturas demasiado bajas o excesivamente altas reducen el rendimiento debido al estrés fisiológico que experimentan las plantas.

29.7 Interpretación desde la Ciencia de Datos

Este gráfico representa un ejemplo clásico de relación no lineal.

Modelos lineales presentan dificultades para describir este tipo de comportamiento, mientras que algoritmos como Random Forest o XGBoost pueden aproximarlos con mayor facilidad.

29.8 Reflexión metodológica

No todos los fenómenos siguen líneas rectas.

Comprender la forma que adopta una relación entre variables constituye uno de los pasos más importantes antes de seleccionar un modelo predictivo.

30 Construcción de modelos predictivos

Después de comprender el comportamiento del conjunto de datos mediante el Análisis Exploratorio de Datos (EDA), el siguiente paso consiste en entrenar diferentes modelos de regresión.

El objetivo no es determinar cuál algoritmo es “mejor” de manera absoluta, sino analizar cómo responde cada uno frente a un fenómeno cuya complejidad ha ido aumentando progresivamente a lo largo de los experimentos.

Se compararán tres enfoques:

- Regresión Lineal
- Random Forest
- XGBoost

La comparación se realizará utilizando exactamente el mismo conjunto de entrenamiento y prueba para garantizar una evaluación objetiva.

```
[42]: # =====  
# Variables predictoras y variable objetivo  
# =====  
  
X = df_exp4[[  
    "Precipitacion_mm",  
    "Temperatura_C",
```

```

    "Radiacion",
    "Materia_Organica_pct",
    "pH",
    "Fertilizacion_kg_ha",
    "Riego_mm"
]]

y = df_exp4["Rendimiento_t_ha"]

print("Variables predictoras:")

display(X.head())

print("\nVariable objetivo:")

display(y.head())

```

Variables predictoras:

	Precipitacion_mm	Temperatura_C	Radiacion	Materia_Organica_pct	pH	\
0	605.813113	16.258057	18.925585	4.363515	6.744786	
1	1153.178591	24.463722	18.704682	4.983407	7.538470	
2	945.394245	32.077754	28.593819	2.252339	7.384547	
3	818.725560	28.841172	18.743193	4.124370	5.323260	
4	398.217708	30.550906	19.079246	3.858730	5.307448	

	Fertilizacion_kg_ha	Riego_mm
0	128.727104	194.477086
1	144.687132	51.715909
2	220.909479	261.718369
3	118.000877	183.934872
4	223.929937	47.161165

Variable objetivo:

```

0    498.576654
1   1206.755200
2    387.729808
3    492.655154
4    141.841970
Name: Rendimiento_t_ha, dtype: float64

```

```

[43]: # =====
# División entrenamiento - prueba
# =====

from sklearn.model_selection import train_test_split

```

```

X_train, X_test, y_train, y_test = train_test_split(

    X,
    y,

    test_size=0.20,

    random_state=42

)

print("="*60)

print("Entrenamiento:", len(X_train))

print("Prueba:", len(X_test))

```

```

=====
Entrenamiento: 800
Prueba: 200

```

```

[44]: # =====
# Regresión Lineal
# =====

from sklearn.linear_model import LinearRegression

modelo_lr = LinearRegression()

modelo_lr.fit(X_train, y_train)

pred_lr = modelo_lr.predict(X_test)

```

```

[45]: # =====
# Random Forest
# =====

from sklearn.ensemble import RandomForestRegressor

modelo_rf = RandomForestRegressor(

    n_estimators=300,

    random_state=42

)

modelo_rf.fit(

```

```

        X_train,

        y_train
    )

pred_rf = modelo_rf.predict(X_test)

```

```

[46]: # =====
# XGBoost
# =====

from xgboost import XGBRegressor

modelo_xgb = XGBRegressor(

    n_estimators=300,

    learning_rate=0.05,

    max_depth=5,

    random_state=42
)

modelo_xgb.fit(

    X_train,

    y_train
)

pred_xgb = modelo_xgb.predict(X_test)

```

31 Comparación del desempeño predictivo

Una vez entrenados los modelos, el siguiente paso consiste en evaluar su capacidad para representar el comportamiento del sistema agrícola.

Para garantizar una comparación objetiva, todos los modelos fueron entrenados utilizando exactamente el mismo conjunto de entrenamiento y evaluados sobre el mismo conjunto de prueba.

Se utilizarán tres métricas ampliamente empleadas en problemas de regresión:

- Coeficiente de Determinación (R^2)

- Error Cuadrático Medio (RMSE)
- Error Absoluto Medio (MAE)

Estas métricas permitirán analizar cómo evoluciona el desempeño de la Estadística Tradicional y del Machine Learning frente a un fenómeno progresivamente más complejo.

```
[49]: import sklearn

print(sklearn.__version__)
```

1.6.1

```
[50]: # =====
# Métricas de evaluación
# =====

from sklearn.metrics import (
    r2_score,
    mean_absolute_error,
    root_mean_squared_error
)

import pandas as pd

# -----
# Tabla comparativa
# -----

resultados = pd.DataFrame({

    "Modelo": [
        "Regresión Lineal",
        "Random Forest",
        "XGBoost"
    ],

    "R2": [
        r2_score(y_test, pred_lr),
        r2_score(y_test, pred_rf),
        r2_score(y_test, pred_xgb)
    ],

    "RMSE": [
        root_mean_squared_error(y_test, pred_lr),
        root_mean_squared_error(y_test, pred_rf),
        root_mean_squared_error(y_test, pred_xgb)
    ],
```

```

    "MAE": [
        mean_absolute_error(y_test, pred_lr),
        mean_absolute_error(y_test, pred_rf),
        mean_absolute_error(y_test, pred_xgb)
    ]

})

# Redondear resultados
resultados = resultados.round(4)

# Ordenar por mejor R²
resultados = resultados.sort_values(
    by="R²",
    ascending=False
).reset_index(drop=True)

# Agregar ranking
resultados.insert(0, "Ranking", range(1, len(resultados) + 1))

display(resultados)

```

	Ranking	Modelo	R²	RMSE	MAE
0	1	XGBoost	0.9633	105.8267	73.9576
1	2	Random Forest	0.9415	133.6907	95.9142
2	3	Regresión Lineal	0.1640	505.3443	376.6968

```

[51]: # =====
# Ranking de desempeño de los modelos
# =====

resultados = resultados.sort_values(
    by="R²",
    ascending=False
).reset_index(drop=True)

resultados.index = resultados.index + 1
resultados.index.name = "Ranking"

display(resultados)

```

	Ranking	Modelo	R²	RMSE	MAE
Ranking					
1	1	XGBoost	0.9633	105.8267	73.9576
2	2	Random Forest	0.9415	133.6907	95.9142
3	3	Regresión Lineal	0.1640	505.3443	376.6968

31.1 Interpretación de resultados

La comparación evidencia cómo el desempeño de los modelos cambia a medida que aumenta la complejidad del fenómeno.

Si el problema mantiene relaciones predominantemente lineales, la Regresión Lineal continúa ofreciendo resultados competitivos.

Sin embargo, cuando aparecen relaciones no lineales e interacciones entre variables, algoritmos como Random Forest y XGBoost comienzan a capturar con mayor precisión la estructura del sistema.

31.2 Reflexión metodológica

La elección de un modelo predictivo no debería basarse únicamente en el valor de una métrica.

Debe considerar también la naturaleza del fenómeno, la interpretabilidad requerida y el equilibrio entre simplicidad y capacidad predictiva.

```
[52]: # =====  
# Comparación: Valores Reales vs Predichos  
# =====  
  
import matplotlib.pyplot as plt  
  
fig, axes = plt.subplots(1, 3, figsize=(18,6))  
  
modelos = [  
    ("Regresión Lineal", pred_lr),  
    ("Random Forest", pred_rf),  
    ("XGBoost", pred_xgb)  
]  
  
for ax, (titulo, pred) in zip(axes, modelos):  
    ax.scatter(  
        y_test,  
        pred,  
        alpha=0.65  
    )  
  
    minimo = min(y_test.min(), pred.min())  
    maximo = max(y_test.max(), pred.max())
```

```

ax.plot(
    [minimo, maximo],
    [minimo, maximo],
    linestyle="--",
    linewidth=2
)

ax.set_title(titulo)

ax.set_xlabel("Valores Reales")


ax.set_ylabel("Valores Predichos")

ax.grid(alpha=0.30)

plt.tight_layout()

plt.show()

```



32 Interpretabilidad del Machine Learning

Además de evaluar la capacidad predictiva de los modelos, resulta fundamental comprender qué variables influyen con mayor intensidad en las predicciones.

Esta interpretación permite contrastar el conocimiento aprendido por los algoritmos con el conocimiento agronómico utilizado durante la construcción del Motor de Simulación Agronómica.

En este apartado se analizará la importancia relativa de las variables estimada por los modelos Random Forest y XGBoost.

```

[53]: # =====
# Importancia de variables - Random Forest
# =====

```

```

import pandas as pd

importancias_rf = pd.DataFrame({

    "Variable": X.columns,

    "Importancia": modelo_rf.feature_importances_

})

importancias_rf = importancias_rf.sort_values(

    by="Importancia",

    ascending=False

)

display(importancias_rf)

```

	Variable	Importancia
1	Temperatura_C	0.414138
4	pH	0.351094
0	Precipitacion_mm	0.185482
3	Materia_Organica_pct	0.018109
6	Riego_mm	0.011677
2	Radiacion	0.010170
5	Fertilizacion_kg_ha	0.009330

```

[54]: # =====
# Importancia de variables - XGBoost
# =====

importancias_xgb = pd.DataFrame({

    "Variable": X.columns,

    "Importancia": modelo_xgb.feature_importances_

})

importancias_xgb = importancias_xgb.sort_values(

    by="Importancia",

    ascending=False

```

```
)

display(importancias_xgb)
```

	Variable	Importancia
4	pH	0.394768
1	Temperatura_C	0.394293
0	Precipitacion_mm	0.164635
3	Materia_Organica_pct	0.020276
6	Riego_mm	0.012614
5	Fertilizacion_kg_ha	0.008326
2	Radiacion	0.005088

```
[55]: # =====
# Comparación de importancia de variables
# =====

import matplotlib.pyplot as plt

fig, axes = plt.subplots(1, 2, figsize=(14, 6))

# -----
# Random Forest
# -----

axes[0].barh(

    importancias_rf["Variable"],

    importancias_rf["Importancia"]

)

axes[0].invert_yaxis()

axes[0].set_title("Random Forest")

axes[0].set_xlabel("Importancia")

# -----
# XGBoost
# -----


axes[1].barh(

    importancias_xgb["Variable"],
```

```

importancias_xgb["Importancia"]
)
axes[1].invert_yaxis()
axes[1].set_title("XGBoost")
axes[1].set_xlabel("Importancia")
plt.suptitle(
    "Importancia relativa de las variables",
    fontsize=15,
    fontweight="bold"
)
plt.tight_layout()
plt.show()

```



32.1 Interpretación agronómica

La importancia de variables representa la contribución relativa de cada factor al proceso de predicción desarrollado por los modelos de Machine Learning.

Es importante destacar que estas métricas no implican causalidad directa, sino que reflejan qué

variables fueron más útiles para explicar las diferencias observadas en el rendimiento agrícola dentro del sistema simulado.

La comparación de estos resultados con el conocimiento utilizado durante la construcción del Motor de Simulación Agronómica permite evaluar si los algoritmos aprendieron relaciones coherentes con la lógica agronómica incorporada al modelo conceptual.

32.2 Interpretación desde Ciencia de Datos

Random Forest y XGBoost estiman la importancia de las variables analizando cuánto contribuye cada una a reducir el error de predicción durante el entrenamiento.

Una mayor importancia indica que una variable aporta información relevante para explicar el comportamiento del rendimiento, aunque dicha importancia también puede reflejar interacciones complejas con otras variables del sistema.

Por esta razón, la importancia de variables debe interpretarse como una medida de influencia predictiva y no como una demostración de causalidad.

32.3 Reflexión metodológica

Uno de los aspectos más interesantes de este análisis consiste en verificar si los algoritmos identifican como más importantes las mismas variables que fueron consideradas fundamentales durante el diseño del Motor de Simulación Agronómica.

Cuando existe coherencia entre el conocimiento experto y el conocimiento aprendido por los modelos, aumenta la confianza en que el sistema predictivo está representando adecuadamente la dinámica del fenómeno estudiado.

En este sentido, la interpretabilidad complementa las métricas tradicionales de desempeño, proporcionando una visión más completa sobre la calidad y consistencia de los modelos desarrollados.

33 Lecciones metodológicas

A lo largo de este notebook se construyó un conjunto de experimentos con complejidad creciente para analizar una pregunta fundamental en Ciencia de Datos:

¿Cuándo la estadística deja de ser suficiente y comienza el Machine Learning?

En lugar de responder esta pregunta desde un enfoque teórico, se diseñó un sistema agrícola simulado que permitió observar cómo evoluciona el desempeño de distintos modelos predictivos a medida que aumenta la complejidad del fenómeno.

Las siguientes lecciones sintetizan los principales aprendizajes obtenidos durante este proceso.

33.1 Evolución de los experimentos

Experimento	Complejidad del fenómeno	Regresión Lineal	Machine Learning
Experimento 1	Baja	Suficiente	No aporta ventajas relevantes

Experimento	Complejidad del fenómeno	Regresión Lineal	Machine Learning
Experimento 2	Baja–Media	Competitiva	Aporta mejoras marginales
Experimento 3	Media	Comienza a perder capacidad explicativa	Empieza a capturar relaciones más complejas
Experimento 4	Alta	Insuficiente	Modela adecuadamente las relaciones no lineales

33.1.1 1. La complejidad del fenómeno determina la complejidad del modelo

La elección de un modelo predictivo no debe responder a tendencias tecnológicas ni a la popularidad de un algoritmo.

Debe estar determinada por la naturaleza del fenómeno que se desea comprender.

Mientras el sistema conserve relaciones predominantemente lineales, los modelos estadísticos tradicionales pueden ofrecer resultados altamente satisfactorios.

Sin embargo, cuando aparecen interacciones, efectos no lineales y dependencias entre múltiples variables, los algoritmos de Machine Learning adquieren una ventaja significativa.

33.1.2 2. Comprender el sistema es más importante que entrenar modelos

El desempeño de un algoritmo depende, en gran medida, de la calidad con la que se representa el fenómeno de estudio.

En este notebook, el diseño del Motor de Simulación Agronómica permitió incorporar conocimiento experto sobre procesos agrícolas antes de aplicar cualquier algoritmo de aprendizaje automático.

Esta etapa conceptual resultó tan importante como el entrenamiento de los modelos.

33.1.3 3. El Análisis Exploratorio de Datos es una etapa indispensable

El EDA permitió comprender la distribución de las variables, identificar relaciones entre ellas y anticipar el comportamiento esperado de los modelos predictivos.

Más que un paso previo al Machine Learning, el análisis exploratorio constituye el puente entre el conocimiento del fenómeno y la construcción de modelos confiables.

33.1.4 4. Las métricas deben complementarse con interpretabilidad

Las métricas como R^2 , RMSE y MAE permiten cuantificar el desempeño predictivo de un modelo.

No obstante, comprender qué variables fueron más relevantes durante el proceso de aprendizaje proporciona una visión mucho más completa del comportamiento del algoritmo.

La interpretabilidad fortalece la confianza en los modelos y facilita su aplicación en contextos reales de toma de decisiones.

33.1.5 5. El Machine Learning potencia el conocimiento experto

Los resultados obtenidos muestran que los algoritmos más avanzados alcanzaron un mejor desempeño cuando el fenómeno presentó relaciones complejas.

Sin embargo, dichos algoritmos no sustituyen el conocimiento del dominio.

Por el contrario, su verdadero potencial surge cuando se combinan con una adecuada comprensión del sistema que se pretende modelar.

En este sentido, la experiencia agronómica utilizada para construir el Motor de Simulación Agronómica constituyó la base sobre la cual los modelos pudieron aprender patrones consistentes y realizar predicciones precisas.

34 Reflexión final

Este notebook no tuvo como objetivo demostrar que un algoritmo es superior a otro.

Su propósito fue mostrar que la elección de un modelo debe ser una consecuencia del conocimiento del fenómeno y no únicamente de la disponibilidad de herramientas computacionales.

A través de cuatro experimentos con complejidad creciente, se evidenció que la Regresión Lineal mantiene un excelente desempeño mientras predominan relaciones simples entre las variables. Sin embargo, cuando el sistema incorpora interacciones, no linealidades y procesos más complejos, los modelos de Machine Learning logran representar con mayor fidelidad la dinámica del fenómeno.

En consecuencia, el Machine Learning no debe entenderse como un reemplazo de la Estadística Tradicional, sino como una extensión natural de ella para abordar problemas cuya complejidad supera la capacidad explicativa de los modelos lineales.

En definitiva, el Machine Learning no comienza cuando aparecen nuevos algoritmos; comienza cuando la complejidad del fenómeno supera la capacidad explicativa de los modelos estadísticos tradicionales.

“Antes de elegir un algoritmo, debemos comprender el fenómeno. Porque los modelos cambian, las herramientas evolucionan y la tecnología avanza; pero el verdadero conocimiento siempre comienza entendiendo el sistema que queremos explicar.”

[]: