

¿CUÁNDO LA ESTADÍSTICA DEJA DE SER SUFICIENTE Y COMIENZA EL MACHINE LEARNING?

UN ENFOQUE METODOLÓGICO MEDIANTE LA
SIMULACIÓN DE UN SISTEMA



Estadística vs Machine Learning

Framework metodológico para seleccionar modelos predictivos en función de la complejidad del fenómeno

Autor: **Víctor Hugo Villegas Ríos**

Consultor Freelance en Ciencia de Datos Aplicada al Medio Ambiente, Agricultura y Análisis Territorial

Python • Machine Learning • Ciencia de Datos • Power BI

Mensaje del Autor

Comprender antes de modelar

Durante muchos años, la conversación sobre Ciencia de Datos ha estado dominada por una pregunta recurrente:

¿Qué algoritmo ofrece el mejor desempeño?

Sin embargo, la experiencia demuestra que esta no es la primera pregunta que deberíamos formularnos.

Antes de seleccionar un modelo predictivo, es necesario comprender la naturaleza del fenómeno que queremos explicar.

Un mismo algoritmo puede ofrecer excelentes resultados en un problema y un desempeño limitado en otro, no por sus capacidades intrínsecas, sino porque la complejidad del sistema que intenta representar es diferente.

Esta investigación nace precisamente de esa reflexión.

Más que comparar modelos predictivos, propone una metodología para comprender **cuándo** la Estadística Tradicional continúa siendo suficiente y **cuándo** la complejidad del fenómeno hace necesario incorporar técnicas de Machine Learning.

El sistema agrícola utilizado durante el estudio constituye únicamente un caso de aplicación.

El verdadero aporte del trabajo es el desarrollo de un **framework metodológico** que puede adaptarse a diferentes dominios del conocimiento.

Espero que este documento contribuya no solo a seleccionar mejores modelos, sino también a fortalecer una forma de trabajo donde la comprensión del fenómeno preceda siempre a la elección de la herramienta.

Víctor Hugo Villegas Ríos

Resumen Ejecutivo

La selección entre modelos estadísticos tradicionales y algoritmos de Machine Learning representa una de las decisiones metodológicas más relevantes dentro de cualquier proyecto de Ciencia de Datos. Sin embargo, con frecuencia esta elección se realiza comparando algoritmos y métricas predictivas, dejando en segundo plano la comprensión del fenómeno que se desea modelar.

El presente trabajo propone un enfoque diferente.

A partir del diseño de un **framework metodológico** y de un conjunto de experimentos con complejidad creciente, se analiza el momento en que la Estadística Tradicional deja de representar adecuadamente un sistema y el Machine Learning comienza a aportar un valor significativo.

Para validar esta propuesta se desarrolló un **Motor de Simulación** que permitió construir cuatro escenarios con niveles crecientes de complejidad. Cada uno fue analizado mediante Análisis Exploratorio de Datos (EDA) y posteriormente modelado utilizando Regresión Lineal, Random Forest y XGBoost.

Los resultados evidencian que la elección del modelo no depende de la sofisticación del algoritmo, sino de la complejidad del fenómeno que se desea comprender.

Más que una comparación entre modelos predictivos, este proyecto presenta un **framework metodológico** que puede aplicarse en distintos dominios del conocimiento para orientar la selección fundamentada de modelos predictivos.



La pregunta que dio origen a esta investigación

Una pregunta antes que un algoritmo

Durante el desarrollo de proyectos de Ciencia de Datos es habitual comenzar preguntando:

¿Qué algoritmo ofrece el mejor desempeño?

Sin embargo, esta investigación parte de una pregunta diferente.

¿Cuándo la complejidad del fenómeno hace necesario utilizar Machine Learning?

Responder esta pregunta implica cambiar el enfoque tradicional.

No se trata de buscar el algoritmo más sofisticado, sino de comprender primero el sistema que se desea representar.

Bajo esta perspectiva, el Machine Learning deja de ser un punto de partida y pasa a convertirse en una consecuencia natural de la complejidad del fenómeno.

Esta idea constituye el principio fundamental sobre el cual se desarrolló todo el framework metodológico.



El Framework Metodológico

Una metodología basada en la comprensión del fenómeno

El framework desarrollado propone un proceso sistemático para seleccionar modelos predictivos en función de la complejidad del sistema analizado.

El proceso comprende siete etapas:

1. Comprensión del fenómeno.
2. Construcción del modelo conceptual.
3. Simulación del sistema.
4. Análisis Exploratorio de Datos (EDA).
5. Entrenamiento de modelos predictivos.
6. Interpretación de resultados.
7. Extracción de lecciones metodológicas.

Este enfoque permite fundamentar la elección del modelo utilizando evidencia obtenida durante el análisis y no únicamente el desempeño alcanzado por los algoritmos.

La complejidad del fenómeno determina la complejidad del modelo.



Estrategia Experimental

Cuatro experimentos con complejidad creciente
Para validar el framework se diseñó un sistema compuesto por cuatro experimentos, cada uno representando un nivel diferente de complejidad

Experimento	Características principales	Resultados esperados
Experimento 1	Relacion lineal simple	La regresion lineal es suficiente
Experimento 2	Incorporacion de nuevas variables	La regresion lineal mantiene un buen desempeño
Experimento 3	Interacciones crecientes	El Machine Learning comienza a tener ventajas
Experimento 4	Relaciones no lineales complejas	Los modelos de Machine Learning superan claramente a la Regresion Lineal



Principales Resultados

Evidencia obtenida

El análisis realizado permitió identificar varios hallazgos relevantes.

- La Regresión Lineal ofrece excelentes resultados cuando predominan relaciones simples entre variables.
- El aumento de la complejidad reduce progresivamente la capacidad explicativa de los modelos lineales.
- Random Forest y XGBoost capturan con mayor precisión relaciones complejas e interacciones entre variables.
- El EDA constituye una etapa indispensable para comprender el comportamiento del sistema antes del modelado.
- La interpretabilidad permite comprender por qué un modelo obtiene determinado desempeño y fortalece la confianza en sus resultados.

El principal resultado del estudio puede resumirse en una idea:

El Machine Learning comienza cuando la complejidad del fenómeno supera la capacidad explicativa de los modelos estadísticos tradicionales.



Aplicaciones del Framework



Un enfoque aplicable a múltiples dominios

Aunque el framework fue validado mediante un caso de estudio basado en un sistema agrícola, su estructura metodológica puede adaptarse a una amplia variedad de problemas.

Entre ellos:

- Agricultura y producción agropecuaria.
- Medio Ambiente y Recursos Naturales.
- Evaluación de Impacto Ambiental.
- Economía y Finanzas.
- Energía.
- Industria.
- Salud.
- Analítica Territorial.
- Ciencias Sociales.
- Sistemas de apoyo a la toma de decisiones.

La metodología propuesta no depende del dominio de aplicación, sino de la comprensión del fenómeno y de la complejidad inherente al sistema estudiado.



Lecciones Metodológicas

Aprendizajes principales

Esta investigación permitió establecer varios principios que orientan la selección de modelos predictivos.

- Comprender el fenómeno siempre precede a la selección del algoritmo.
- La complejidad del sistema debe guiar el proceso de modelado.
- La Estadística Tradicional y el Machine Learning no compiten; se complementan.
- El conocimiento del dominio fortalece la calidad de los modelos predictivos.
- La interpretabilidad constituye un componente esencial para generar confianza en los resultados.

No elegimos Machine Learning porque sea más moderno. Lo elegimos porque el fenómeno ya no puede describirse adecuadamente mediante relaciones lineales simples.

Sobre el Autor

Víctor Hugo Villegas Ríos

Ingeniero Agrónomo, Posgrado en Medio Ambiente y Recursos Naturales

Consultor Freelance en Ciencia de Datos Aplicada al Medio Ambiente,
Agricultura y Análisis Territorial

Áreas de especialización

Análisis y Ciencia de Datos | Machine Learning | Python | Power BI

QGIS | UX / UI |

Líneas de Acción:

- Ciencia de Datos aplicada al Medio Ambiente y la Agricultura.
- Frameworks metodológicos para modelado predictivo.
- Evaluación de Impacto Ambiental.
- Valoración Económica Ambiental.
- Análítica Territorial.

**"Antes de elegir un algoritmo, debemos comprender el fenómeno.
Porque los modelos cambian, las herramientas evolucionan y la
tecnología avanza; pero el verdadero conocimiento siempre comienza
entendiendo el sistema que queremos explicar."**